



Escuela Técnica Superior de
Ingeniería Informática

TRABAJO FIN DE GRADO

SavePoint: una plataforma de catalogación de videojuegos como banco de pruebas de algoritmos de recomendación

Realizado por
Felipe Peña Núñez

Para la obtención del título de
Grado en Ingeniería Informática - Ingeniería del Software

Dirigido por
José Enrique Sánchez López
Aitor Rodríguez Dueñas

En el departamento de
Lenguajes y Sistemas Informáticos

Convocatoria de octubre, curso 2025/2026

*A quienes creyeron en este proyecto desde el principio y me acompañaron, con paciencia y
confianza, hasta el final.*

Agradecimientos

Quisiera expresar mi agradecimiento a todas las personas que han contribuido, de una forma u otra, a la realización de este Trabajo Fin de Grado.

En primer lugar, agradezco a mi tutores, su orientación, disponibilidad y apoyo durante las distintas fases del proyecto.

También agradezco a mi familia y a mis amigos el apoyo constante, la paciencia y la comprensión mostrados durante este periodo. Sus ánimos han sido especialmente importantes en los momentos de mayor dificultad.

Finalmente, agradezco a la Escuela Técnica Superior de Ingeniería y a la Universidad de Sevilla la formación recibida durante el Grado en Ingeniería Informática, así como los conocimientos y recursos que han permitido desarrollar este trabajo.

Resumen

SavePoint nace de aplicar al videojuego el patrón de catalogación personal de plataformas como Goodreads o Letterboxd, con un inventario de propiedad física y digital que esos productos no necesitan resolver; sobre esa base, el trabajo convierte la plataforma en un banco de pruebas reproducible para sistemas de recomendación. Se ha diseñado e implementado el producto con catálogo, biblioteca, copias físicas y digitales, valoraciones, listas, comentarios, perfiles, privacidad, relaciones sociales y recomendaciones. La aplicación y la evaluación reproducible de los recomendadores son las dos partes complementarias del trabajo: la primera recoge y gobierna los datos que la segunda necesita.

El sistema compara dieciséis algoritmos de referencia: baselines, variantes basadas en contenido, filtrado colaborativo por vecinos e híbridos con reordenación por diversidad. Se describen la representación de obras y perfiles, la ponderación de etiquetas, la similitud por facetas, la calidad externa, la popularidad, la evidencia negativa, el arranque en frío y la combinación híbrida. El protocolo offline fija corpus, snapshots, semillas, candidatas comunes, exclusiones y métricas para $K \in \{5, 10, 20\}$.

La evidencia publicada v15 utiliza 400 usuarios sintéticos activos y 79 usuarios evaluables, con una sola ejecución del test. Los resultados permiten comparar internamente algoritmos bajo el corpus y protocolo congelados, pero no representan usuarios reales ni justifican generalizaciones automáticas. La memoria distingue de forma explícita esa publicación del contrato de implementación vigente, que evolucionó posteriormente.

Se ha aplicado una metodología de ingeniería asistida por agentes, gobernada mediante el método Get Stuff Done y organizada conceptualmente con Obsidian. Las herramientas se emplearon bajo dirección y revisión humana, manteniéndose la decisión final y la responsabilidad sobre el análisis, el diseño, la implementación y la validación en la dirección del proyecto. La trazabilidad entre requisitos, código, pruebas, decisiones y artefactos versionados constituye una aportación metodológica del trabajo.

Palabras clave: videojuegos, sistemas de recomendación, evaluación offline, reproducibilidad, filtrado colaborativo, recomendación basada en contenido, procedencia de datos.

Abstract

SavePoint grew out of applying to video games the personal cataloguing pattern of platforms such as Goodreads or Letterboxd, adding an inventory of physical and digital ownership that those products never had to solve; on that basis, the project turns the platform into a reproducible testbed for recommender systems. The platform includes a catalogue, library, physical and digital copies, ratings, lists, comments, profiles, privacy, social relations and recommendations. The application and the reproducible evaluation of the recommenders are the two complementary halves of the work: the former collects and governs the data the latter needs.

The system compares sixteen reference algorithms: baselines, content-based variants, neighbourhood collaborative filtering, and hybrid approaches with diversity re-ranking. This report describes item and user representations, tag weighting, facet similarity, external quality, popularity, negative evidence, cold start, and hybrid combination. The offline protocol fixes corpus, snapshots, seeds, shared candidates, exclusions and ranking metrics at $K \in \{5, 10, 20\}$.

The published v15 evidence uses 400 active synthetic users and 79 evaluable users, with a single test run. It supports an internal comparison under the frozen corpus and protocol, but it does not represent real users or justify automatic generalisation. This report explicitly separates that publication from the later implementation contract.

An agent-assisted engineering methodology governed through the Get Stuff Done method and conceptually organised with Obsidian was applied throughout the project. The tools were used under human direction and review, while final decisions and responsibility for analysis, design, implementation and validation remained with Felipe Peña Núñez.

Keywords: video games, recommender systems, offline evaluation, reproducibility, collaborative filtering, content-based recommendation, data provenance.

Acrónimos

La siguiente lista recoge los acrónimos empleados en la memoria. Cada uno se define también en su primer uso dentro del cuerpo del texto, con la forma larga seguida de la sigla. En el resumen y en el *abstract* se han escrito las formas largas, sin siglas.

ADR Registro de decisión de arquitectura (del inglés *architecture decision record*).

API Interfaz de programación de aplicaciones (del inglés *application programming interface*).

CC0 Dedicación al dominio público *Creative Commons Zero*.

CDN Red de distribución de contenidos (del inglés *content delivery network*).

CSRF Falsificación de petición en sitios cruzados (del inglés *cross-site request forgery*).

CSV Valores separados por comas (del inglés *comma-separated values*).

DLC Contenido descargable (del inglés *downloadable content*).

DoS Denegación de servicio (del inglés *denial of service*).

DRF *Django REST Framework*.

DSA Acuerdo de servicios para desarrolladores (del inglés *developer services agreement*).

DTO Objeto de transferencia de datos (del inglés *data transfer object*).

E2E De extremo a extremo (del inglés *end to end*).

GSD *Get Stuff Done*, método de desarrollo dirigido por especificación para agentes.

HTTP Protocolo de transferencia de hipertexto (del inglés *hypertext transfer protocol*).

IDF Frecuencia inversa de documento (del inglés *inverse document frequency*).

IGDB *Internet Game Database*.

JSON Notación de objetos de JavaScript (del inglés *JavaScript object notation*).

LTS Soporte a largo plazo (del inglés *long-term support*).

MAP Precisión media (del inglés *mean average precision*).

ML Aprendizaje automático (del inglés *machine learning*).

MMR Relevancia marginal máxima (del inglés *maximal marginal relevance*).

nDCG Ganancia acumulada descontada normalizada (del inglés *normalised discounted cumulative gain*).

ORM Mapeo objeto-relacional (del inglés *object-relational mapping*).

PaaS Plataforma como servicio (del inglés *platform as a service*).

RAWG Base de datos de videojuegos usada como fuente de contraste (*RAWG Video Games Database*).

REST Transferencia de estado representacional (del inglés *representational state transfer*).

SSR Renderizado en el servidor (del inglés *server-side rendering*).

TFG Trabajo Fin de Grado.

UAT Pruebas de aceptación de usuario (del inglés *user acceptance testing*).

UI Interfaz de usuario (del inglés *user interface*).

UUID Identificador único universal (del inglés *universally unique identifier*).

WCAG Pautas de accesibilidad para el contenido web (del inglés *web content accessibility guidelines*).

XSS Ejecución de secuencias de comandos en sitios cruzados (del inglés *cross-site scripting*).

Índice general

Agradecimientos	I
Resumen	II
Abstract	III
Acrónimos	IV
1 Introducción, problema y objetivos	1
1.1. Motivación, contexto y problema	1
1.2. Objetivos y alcance	2
1.3. Estructura de la memoria	3
2 Estado del arte y fundamentos de evaluación	4
2.1. Fuentes de datos de videojuegos	4
2.2. Sistemas de recomendación y su evaluación	4
2.3. El método GSD: agentes coordinados sobre un contexto compartido	6
3 Gestión, metodología y planificación	7
3.1. Objetivos de gestión y método de trabajo	7
3.2. Planificación viva y trazabilidad	8
3.3. Agentes especializados y contrato de contexto	12
3.4. Planificación del laboratorio de evaluación	14
3.5. Planificación temporal	15
3.6. Estimación de esfuerzo y presupuesto	16
3.7. Riesgos y mitigaciones	17
3.8. Lecciones aprendidas y valoración de la metodología	18
4 Análisis del problema	20
4.1. Actores del sistema	20
4.2. Requisitos de información: modelo de dominio	20
4.3. Requisitos funcionales y casos de uso	22
4.4. Requisitos de la evaluación de recomendadores	22
4.5. Requisitos no funcionales y reglas de negocio	25
4.6. Trazabilidad de requisitos	26
5 Diseño y arquitectura	29
5.1. Arquitectura del sistema	29
5.2. Decisiones de arquitectura	31
5.3. Modelo de datos, API y sesión	32
5.4. Diseño de la interfaz de usuario	34

5.5.	Diseño de los algoritmos de recomendación	35
5.5.1.	Representación de una obra y del perfil de la persona usuaria	36
5.5.2.	Similitud de contenido y señales escalares de la candidata	38
5.5.3.	Las tres familias y sus dieciséis variantes	40
5.5.4.	Variantes publicadas en la aplicación	42
5.5.5.	Alternativas descartadas y su justificación	42
5.6.	Diseño del laboratorio de evaluación	43
6	Implementación y pruebas	45
6.1.	Entorno reproducible y dependencias	45
6.2.	Adquisición y gobierno de datos	46
6.2.1.	Fuentes: corpus de Wikidata y catálogo de IGDB	46
6.2.2.	Congelación y gobierno del corpus	48
6.2.3.	Ratings externos y aislamiento de la evaluación	49
6.3.	Backend	50
6.3.1.	Comandos de gestión y del laboratorio	50
6.3.2.	Vistas, búsqueda y filtrado	50
6.3.3.	Recomendadores en la aplicación	51
6.4.	Frontend	52
6.5.	Pruebas y verificación	55
6.5.1.	Verificación de los datos y del laboratorio	56
6.5.2.	Gates de evidencia y verificación independiente	57
6.5.3.	Revisión de código	58
6.6.	Despliegue	59
7	Evaluación y resultados	62
7.1.	Protocolo de evaluación	62
7.2.	Evolución del protocolo: tres intentos, no uno	63
7.3.	Resultados publicados	65
7.4.	Significación estadística	69
7.5.	Diversidad, cobertura y amenazas a la validez	70
8	Conclusiones y continuidad	72
8.1.	Grado de cumplimiento de los objetivos	72
8.2.	Limitaciones y trabajo futuro	72
8.3.	Aportaciones y valoración final	73
	Bibliografía	74

Índice de figuras

3.1. Ciclo de un incremento en el método GSD y los artefactos que produce cada paso.	8
3.2. Grafo del vault de Obsidian de SavePoint (ideas-vault/), coloreado por categoría de nota. Se muestra la componente conexa principal, ciento veintitrés notas de las ciento cincuenta que contiene el vault; el resto enlaza solo entre sí en subgrafos pequeños y aislados. Los nodos de mayor tamaño, como 00 - Índice o los mapas de investigación y de datos, son las notas con más enlaces entrantes y salientes.	11
3.3. Calendario de las iteraciones y de los hitos H0 a H7 del trabajo. . . .	16
4.1. Modelo de dominio de SavePoint, agrupado por catálogo, biblioteca personal, cuentas y amistades, y laboratorio de evaluación. Cada flecha parte de la entidad que contiene la clave foránea y apunta a la entidad que referencia; la flecha de doble punta indica una relación de muchos a muchos y la discontinua, una referencia opcional. De las copias en propiedad solo se dibujan sus referencias a la versión de lanzamiento y a la edición; IgdbImportRun y AssetAttribution se omiten de la figura y se describen en el texto.	21
4.2. Diagrama de casos de uso del sistema, por actor principal. Cada línea une un actor con los casos de uso que ejecuta.	25
5.1. Arquitectura de SavePoint: el navegador solo habla con Next.js, que reescribe las llamadas hacia Django y DRF; los comandos de ingesta y el runner de evaluación escriben en PostgreSQL fuera de la petición HTTP.	30
5.2. Página de inicio con tema claro y sin sesión iniciada.	34
5.3. Página de inicio con tema oscuro y con sesión iniciada.	35
5.4. Tubería de la evaluación offline, de los datos congelados al artefacto versionado.	44
6.1. Flujo de los datos del catálogo, desde las fuentes hasta el laboratorio de evaluación.	46
6.2. Catálogo con tema oscuro, búsqueda y filtros por plataforma, género, año y valoración. Fuente: captura del proyecto.	53
6.3. Colección de la persona usuaria con tema oscuro, con el estado y la valoración de cada juego. Fuente: captura del proyecto.	54
6.4. Vista de recomendaciones organizada por estanterías, con tema oscuro. Fuente: captura del proyecto.	55
6.5. Vista detallada de recomendaciones, con las señales de afinidad y tema oscuro. Fuente: captura del proyecto.	55

6.6.	Topología de despliegue público y cadena de arranque en Render, en la que cada paso es idempotente y un paso fallido detiene el arranque. Docker Compose local (base de datos, API y frontend) construye las mismas imágenes sin depender de estos tres servicios.	60
7.1.	<i>nDCG@10</i> de los dieciséis algoritmos en la evaluación v15, por familia. El borde grueso marca las tres variantes publicadas en la aplicación.	68

Índice de tablas

1.1. Comparación de SavePoint con los productos de referencia.	1
3.1. Artefactos principales del árbol .planning/.	9
3.2. Subagentes empleados y su responsabilidad.	12
3.3. Lista de hitos del trabajo.	15
3.4. Estimación de horas por bloque de trabajo.	16
3.5. Estimación de esfuerzo y presupuesto del proyecto.	17
3.6. Riesgos identificados y sus mitigaciones.	18
4.1. Actores del sistema.	20
4.2. Áreas del modelo de dominio y requisitos de información asociados.	22
4.3. Requisitos funcionales considerados en el análisis del sistema.	23
4.4. Casos de uso del sistema.	24
4.5. Reglas de negocio.	26
4.6. Trazabilidad de requisitos de SavePoint, por familia.	27
4.7. Matriz de trazabilidad de requisito a evidencia.	28
5.1. Registros de decisión de arquitectura vigentes.	32
5.2. Puntos de acceso principales de la API.	33
5.3. Peso fijo W_f de cada familia de faceta en el vector de contenido, f_s -v13. Los valores son una decisión de diseño de SavePoint, no una constante de la literatura.	37
5.4. Fórmula de combinación de las diez variantes basadas en contenido.	40
5.5. Alternativas consideradas y motivo de exclusión.	43
6.1. Versiones principales del entorno reproducible.	45
6.2. Comparación DATA-04 de fuentes para el catálogo a escala real.	47
6.3. Evidencia agregada de congelación de la importación de IGDB.	48
6.4. Criterios de éxito verificados y su veredicto.	57
6.5. Hallazgos de la revisión de código de todo el repositorio.	58
6.6. Topología pública aprobada, de coste cero.	59
7.1. Resultados v15 publicados para la cohorte indicada. No son resultados con usuarios reales.	66
7.2. $nDCG$ publicado por algoritmo y corte K en v15.	67
7.3. Éxitos por algoritmo a $K = 10$: ítems retenidos recuperados sobre 202; usuarios que recuperaron al menos uno de los suyos sobre 79.	68
7.4. Comparaciones por pares más relevantes sobre $nDCG@10$, con corrección de Holm sobre las ciento veinte comparaciones totales.	70

Índice de extractos de código

6.1. Lista fija de ordenaciones del catálogo, con desempate por identificador canónico (<code>apps/api/catalogue/search.py</code>).	51
6.2. Cálculo del peso de actividad de una entrada de biblioteca.	52
6.3. Reescritura del mismo origen hacia el backend (<code>apps/web/next.config.ts</code>).	54

1. Introducción, problema y objetivos

1.1. Motivación, contexto y problema

Goodreads y Letterboxd son dos servicios web de catalogación social: el primero, para libros, y el segundo, para cine [1, 2]. Ambos comparten un patrón: una ficha canónica por obra, independiente de la edición concreta que posea cada persona; un estado de consumo personal, como pendiente, en curso o terminado; una valoración con una escala consistente; listas ordenadas. Ni uno ni otro representan la propiedad material con detalle, porque un libro o una película no plantean el problema de inventario que sí plantea una consola con juegos en cartucho, disco y descarga.

En el ámbito del videojuego, Backloggd traslada casi literalmente el modelo de Letterboxd [3], con buen tratamiento del backlog, pero sin inventario de copias ni ambición de recomendación. OpenCritic agrega puntuaciones de prensa y es una referencia de densidad visual y de tratamiento de la nota, más que un catalogador personal. Steam ofrece una biblioteca personal rica, aunque acoplada a su tienda y limitada a lo comprado en ella. La web de IGDB expone un catálogo amplio y bien modelado, orientado a la consulta y no a la gestión de una colección. La Tabla 1.1 resume la comparación.

Producto	Ficha canónica	Backlog	Inventario de copias	Recomendación
Goodreads	Sí	Sí	No	Sí
Letterboxd	Sí	Sí	No	Parcial
Backloggd	Sí	Sí	No	No
OpenCritic	Sí	No	No	No
Steam	Parcial	Parcial	Solo digital de su tienda	Sí
IGDB.com	Sí	No	No	No
SavePoint	Sí	Sí	Sí	Sí

Tabla 1.1: Comparación de SavePoint con los productos de referencia.

El hueco que SavePoint ocupa se ve en la última columna de la Tabla 1.1: ningún producto reúne un inventario detallado de propiedad material con un catálogo a escala real y un banco de pruebas de recomendación abierto y reproducible. Es un problema propio del videojuego: un mismo título puede poseerse a la vez en cartucho, en disco y en descarga, y en más de una plataforma, una distinción que no tiene ficha ni equivalente en un libro o una película.

SavePoint se propone cubrir ese hueco. Aplica al videojuego el patrón de catalogación personal de Goodreads y Letterboxd, con ficha canónica de cada obra,

biblioteca, valoraciones y relaciones de amistad, y añade lo que esos productos no necesitan y este medio sí: un inventario de copias físicas y digitales por edición y plataforma, con procedencia de datos verificable en lugar de un catálogo mantenido a mano. De ello se desprenden tres aportaciones. La primera es un producto de catalogación de videojuegos que combina inventario de propiedad material, catálogo a escala real y procedencia de datos documentada, un conjunto que ningún servicio existente reúne, como muestra la Tabla 1.1. La segunda es un banco de pruebas reproducible para la comparación de recomendadores, con corpus citable, usuarios sintéticos y procedencia de datos documentada, que se explota mediante un protocolo de evaluación congelado y una comparación real entre dieciséis algoritmos, presentada en el Capítulo 7. La tercera es la propia metodología de ingeniería asistida por agentes, aplicada de forma sistemática y versionada en el repositorio, de manera que el proceso que produjo el sistema es tan inspeccionable y reproducible por un tercero como el sistema mismo; el Capítulo 3 la desarrolla en profundidad.

El trabajo es, ante todo, un desarrollo de ingeniería del software: el diseño, la construcción, la verificación y el despliegue de una plataforma web completa para catalogar videojuegos, mantener una biblioteca personal y registrar valoraciones, listas, copias, comentarios y relaciones sociales. El módulo de recomendación y su evaluación forman parte de esa plataforma y tienen el mismo peso que el resto: sin un catálogo gobernado y una biblioteca con señales reales no hay nada que recomendar, y sin una evaluación reproducible no hay forma honesta de saber si lo recomendado funciona. La plataforma recoge y gobierna las señales que los algoritmos consumen, y el laboratorio compara esos algoritmos sobre los mismos datos.

Una lista de recomendaciones no es evidencia suficiente de que un algoritmo funciona mejor que otro. Sin un corpus congelado, una población definida, una división conocida y artefactos identificables, dos ejecuciones pueden parecer comparables aunque en realidad respondan a experimentos distintos, con datos distintos o con criterios de éxito distintos. SavePoint separa por ello, de forma deliberada, la aplicación que presenta resultados a un usuario de los trabajos offline que construyen y evalúan esos rankings. Esa separación no es solo una decisión de arquitectura: se diseñó, implementó y validó mediante código, pruebas y evidencias versionadas. Es esa separación la que permite que las conclusiones del Capítulo 7 de esta memoria se puedan volver a comprobar.

1.2. Objetivos y alcance

El objetivo general del trabajo es construir una plataforma de catalogación de videojuegos que sirva, al mismo tiempo, como banco de pruebas reproducible para recomendación basada en contenido, colaborativa e híbrida. De ahí se derivan las cuestiones que el trabajo aborda: qué señales de un videojuego (género, plataforma, etiquetas curadas, calidad externa, popularidad) se pueden representar de forma explicable en un catálogo real; cómo cambia la recuperación de un ítem relevante cuando se combinan contenido, popularidad, vecindad entre usuarios y

diversidad de la lista resultante; y qué conclusiones son defendibles cuando el corpus y la población de usuarios son, como se explica más abajo, sintéticos y no personas reales.

Los objetivos específicos son gobernar el catálogo y su procedencia de datos; modelar biblioteca, privacidad y relaciones sociales con el mismo nivel de cuidado que el catálogo; implementar tanto los algoritmos de referencia (*baselines*) como las tres familias de recomendación descritas en el Capítulo 2; publicar un protocolo offline con candidatas comunes para que la comparación entre algoritmos sea justa; y conservar hashes, configuraciones y artefactos que hagan auditable cada resultado. La expectativa de partida del trabajo no afirma la superioridad universal de ningún algoritmo: bajo el protocolo publicado, combinar señales de contenido, popularidad y vecindad puede mejorar la recuperación frente a los *baselines* más simples, pero esa mejora debe contrastarse sin confundir una diferencia numérica con significación estadística o con validez fuera del corpus y la población con los que se midió.

El alcance funcional del producto incluye catálogo, importación gobernada de datos, biblioteca, copias físicas y digitales, valoraciones, listas, comentarios, perfiles, privacidad, módulo social, recomendaciones y las medidas de seguridad y copia de seguridad propias de un servicio con usuarios. De las dieciséis variantes de recomendación evaluadas, la aplicación publica tres, según se explica en la Sección 5.5.4. El alcance de la evaluación, en cambio, se limita a una publicación de evidencia concreta, identificada como v15 y descrita en el Capítulo 7, con una única ejecución del test. Conviene subrayar que estos usuarios sintéticos no son personas reales, sino perfiles generados de forma controlada para poder ejercitar el sistema de recomendación sin depender de una base de usuarios real que este TFG no tiene tiempo ni alcance para reunir. Los resultados, por tanto, dependen del corpus concreto, de la semilla aleatoria, de la división de datos y del protocolo empleados: no permiten generalizar automáticamente a preferencias de jugadores reales ni declarar un método como mejor fuera de esas condiciones.

1.3. Estructura de la memoria

La memoria sigue el recorrido natural de un proyecto de ingeniería del software, tratando la plataforma y el estudio de recomendadores en un único hilo. El Capítulo 2 revisa las fuentes de datos, los sistemas de recomendación y su evaluación, y el método de trabajo. El Capítulo 3 describe la gestión, la metodología y la planificación del trabajo, con su calendario, su presupuesto y sus riesgos. El Capítulo 4 recoge el análisis del problema: actores, requisitos de la plataforma y de la evaluación de recomendadores, reglas de negocio y trazabilidad. El Capítulo 5 presenta el diseño y la arquitectura, incluidos los algoritmos de recomendación con sus fórmulas y ponderaciones. El Capítulo 6 describe la implementación, los datos, las pruebas y el despliegue. El Capítulo 7 somete las dieciséis variantes al protocolo de evaluación y presenta los resultados. El Capítulo 8 cierra con el grado de cumplimiento de los objetivos, las limitaciones y las líneas de continuación.

2. Estado del arte y fundamentos de evaluación

Este capítulo revisa el terreno técnico sobre el que se construye SavePoint. Examina primero las fuentes de datos de videojuegos disponibles y sus condiciones de uso, después el panorama de los sistemas de recomendación y de su evaluación reproducible, con el vocabulario y las métricas concretas que el resto de la memoria usa sin volver a introducirlas, y termina con las metodologías de desarrollo asistido por agentes de código. Los productos de referencia con los que se compara SavePoint se presentan en la Sección [1.1](#).

2.1. Fuentes de datos de videojuegos

Tres fuentes públicas cubren la mayor parte del catálogo de videojuegos: Wikidata, IGDB y RAWG. Difieren sobre todo en su licencia y en sus condiciones de reutilización, que son determinantes para un trabajo que debe citar fuentes defendibles. Wikidata publica sus datos estructurados bajo la dedicación al dominio público *Creative Commons Zero* (CC0), la licencia más limpia de las tres, aunque el modelado de género y plataforma para videojuegos es desigual y depende de la edición voluntaria [\[4\]](#). Sus archivos multimedia viven en Wikimedia Commons y no comparten esa licencia: cada imagen lleva su propia condición, que puede exigir crédito, de modo que su reutilización requiere una revisión por archivo [\[5\]](#). IGDB, propiedad de Twitch, ofrece una API de versión 4 con una entidad de plataforma de primera clase y se sirve bajo el *Twitch Developer Services Agreement* (DSA) [\[6, 7\]](#). RAWG ofrece una cobertura comparable, con metadatos de tienda, pero su nivel gratuito es más restrictivo en cuota y en atribución [\[8\]](#). La Tabla [6.2](#), en la Sección [6.2](#), compara las tres fuentes y recoge la elección de Wikidata para el corpus curado inicial y de IGDB para el catálogo a escala real.

2.2. Sistemas de recomendación y su evaluación

Los sistemas de recomendación se agrupan de forma clásica en tres familias [\[9, 10\]](#). Los métodos basados en contenido describen cada ítem con un vector de rasgos, como género, plataforma o etiquetas, para recomendar ítems parecidos a los que la persona ha valorado bien; su ventaja es que funcionan con un solo usuario y explican bien sus resultados, mientras que su límite es la endogamia, es decir, la tendencia a recomendar siempre más de lo mismo. Los métodos de filtrado colaborativo ignoran el contenido y explotan la matriz de interacciones entre personas e ítems, con la hipótesis de que quienes coincidieron en el pasado volverán a coincidir [\[11\]](#); capturan gustos que el contenido no

expresa, pero sufren el problema del arranque en frío cuando un usuario o un ítem no tienen historial. Los métodos híbridos combinan ambas señales para mitigar las debilidades de cada una [12]. SavePoint implementa y compara, sobre su propio catálogo, representantes de las tres familias, con la formulación y la comparación con datos reales que desarrollan la Sección 5.5 y el Capítulo 7.

La parte más delicada no es implementar los algoritmos, sino evaluarlos de forma comparable [13, 14]. La literatura señala varios riesgos recurrentes: ajustar los hiperparámetros sobre el conjunto de prueba, comparar algoritmos con repartos o candidatos distintos, medir solo la precisión y olvidar la cobertura, la diversidad o la novedad, o extraer conclusiones sobre personas reales a partir de simulaciones sintéticas. El trabajo de Cremonesi y otros mostró además que las métricas de error sobre la valoración predicha y las métricas de acierto sobre la lista recomendada pueden ordenar los algoritmos de forma distinta [15]. La respuesta metodológica aceptada es fijar por adelantado, de forma inmutable, el corpus, el reparto, las exclusiones, las métricas, las semillas y el presupuesto de ajuste, antes de comparar nada. En SavePoint este principio se concreta en un protocolo offline congelado y versionado, descrito en el Capítulo 7. Ese protocolo deja la comparación preparada y repetible, pero no debe confundirse con una afirmación sobre usuarios reales: los resultados que presenta esta memoria se miden sobre un corpus y una población sintética concretos, como se explica en el Capítulo 1.

El resto de la memoria usa, sin volver a introducirlo, un vocabulario concreto de evaluación que conviene fijar aquí. Evaluar un recomendador sin usuarios reales delante exige fijar por adelantado, antes de mirar ningún resultado y no después, cinco decisiones: la tarea concreta que se mide (recomendar los siguientes K ítems que a una persona le interesarán, no predecir la nota exacta que pondría), el criterio de relevancia que separa un acierto de un fallo, el conjunto de candidatas sobre el que compite cada algoritmo, la división de los datos entre lo que el modelo puede ver y lo que se usa para medir, y la forma de agregar el resultado por usuario en una única cifra por algoritmo. SavePoint fija estas cinco decisiones en un protocolo versionado que el Capítulo 7 describe con detalle.

Precision at K mide qué proporción de los K ítems recomendados resultan relevantes; *recall at K* mide qué proporción de todos los ítems relevantes que existen aparecen entre esos K . Ninguna de las dos distingue la posición dentro de la lista: acertar en el primer puesto cuenta igual que acertar en el último. Para corregir esa carencia se usa el *normalized discounted cumulative gain* [16] (nDCG), que descuenta el valor de un acierto cuanto más abajo aparece en la lista y lo normaliza frente al orden ideal posible, de modo que premia a los algoritmos que además de acertar, acierten pronto. El *mean average precision* (MAP) promedia, para cada usuario, la precisión acumulada en cada posición donde hubo un acierto y después promedia ese valor entre usuarios; es sensible tanto a la cantidad de aciertos como a su posición, lo que lo hace más exigente que la precisión simple.

Estas cuatro métricas comparten una limitación de fondo: ninguna equivale a satisfacción humana, porque miden coincidencia con un historial pasado, no si a la persona le va a gustar de verdad lo que se le recomienda. Por eso se completan con tres métricas de otra naturaleza. La diversidad mide cuánto se parecen entre

sí los ítems dentro de una misma lista recomendada: penaliza a un algoritmo que acierta mucho pero siempre con variaciones del mismo juego. La novedad mide cuánto se aleja la recomendación de lo obvio o lo ya muy popular. La cobertura mide qué proporción del catálogo entero llega a aparecer alguna vez recomendada, en lugar de concentrarse siempre en el mismo puñado de éxitos. Un recomendador que maximiza solo precisión o nDCG puede hacerlo a costa de las tres, recomendando siempre lo mismo a todo el mundo; la Sección 5.5 explica cómo SavePoint reordena sus listas para compensarlo.

2.3. El método GSD: agentes coordinados sobre un contexto compartido

Get Stuff Done (GSD) es un método de trabajo que organiza el desarrollo en agentes especializados coordinados a través de un contexto compartido y versionado, en lugar de a través de una conversación continua entre una persona y una única herramienta. La observación de partida es sencilla: una tarea larga tiende a perder coherencia entre lo decidido al principio y lo decidido al final, sobre todo cuando se turnan varios agentes para avanzarla, y esa pérdida de coherencia es tanto más probable cuanto más depende de que alguien recuerde el historial completo de lo hecho hasta el momento [17]. GSD responde a esa observación con un principio de diseño simple: aislar cada incremento de trabajo en una tarea atómica, ejecutar cada tarea con el contexto limpio y hacer que la información necesaria para continuar viaje entre tareas a través de ficheros versionados en el propio repositorio, nunca a través del historial de una conversación.

Sobre ese principio, GSD organiza el desarrollo en incrementos que recorren un ciclo ordenado [18]. Lo interesante del método no es tanto ese ciclo, habitual en cualquier proceso de ingeniería disciplinado, como la forma en que lo instrumenta: cada incremento se apoya en un árbol de ficheros compartido que agentes con roles distintos leen y escriben de forma coordinada, cada uno acotado a su función y sin heredar el razonamiento de los demás. El Capítulo 3 describe con detalle cómo se aplicó este enfoque a SavePoint, qué mecanismos concretos lo instrumentan y qué evidencia dejó.

3. Gestión, metodología y planificación

Este capítulo describe cómo se gobernó el trabajo de principio a fin y por qué esa forma de gobernarlo es, en sí misma, una aportación del TFG y no solo un procedimiento administrativo. La mayor parte de los proyectos de software describen su metodología en un párrafo y pasan enseguida al producto. Aquí se dedica un capítulo completo porque el propio proceso de ingeniería, gobernado de forma sistemática mediante GSD, se trató con la misma exigencia de evidencia, trazabilidad y verificación que cualquier otra parte del sistema.

El capítulo fija primero los objetivos de gestión y el método de trabajo, describe después la planificación viva, la trazabilidad y los agentes que instrumentan ese método, recoge la planificación del laboratorio de evaluación, la planificación temporal, el esfuerzo y el presupuesto; termina con los riesgos, las lecciones aprendidas y una valoración de la metodología.

3.1. Objetivos de gestión y método de trabajo

La gestión del proyecto persigue cuatro objetivos. El primero es entregar valor de forma incremental, con cada incremento vertical utilizable y verificado, en lugar de una integración final de riesgo. El segundo es que toda afirmación de la memoria tenga respaldo: una decisión registrada, una verificación independiente o una firma de aceptación. El tercero es mantener el alcance bajo control a lo largo de sucesivos incrementos, sin que el trabajo de uno contamine el de otro. El cuarto es que el proceso de ingeniería quede documentado con el mismo rigor que el producto, de modo que un tercero pueda reconstruir no solo el sistema, sino la secuencia de decisiones que lo produjo.

El ciclo de vida del proyecto se gobernó mediante el método *Get Stuff Done* (GSD) [18], cuyo principio de aislamiento del contexto presenta la Sección 2.3. GSD descompone el trabajo en incrementos verticales y somete cada uno a un ciclo ordenado de cuatro pasos que la Figura 3.1 resume: discutir, planificar, ejecutar y verificar. Cada paso produce un artefacto escrito que actúa como fuente de verdad del siguiente.




Figura 3.1: Ciclo de un incremento en el método GSD y los artefactos que produce cada paso.

En la práctica, cada incremento se abre con una discusión que fija por escrito sus decisiones y supuestos. Si tiene interfaz, se establece además un contrato de diseño con sus componentes y estados. A continuación se investiga y se redacta el plan, que lo descompone en tareas atómicas con criterios de aceptación y se comprueba antes de tocar código. La ejecución implementa ese plan, confirma los cambios en el control de versiones y registra en un resumen lo realmente hecho y las desviaciones. Por último, la verificación comprueba, de forma independiente, que el objetivo se ha alcanzado. Una revisión de código somete después los cambios a un análisis de seguridad, rendimiento y corrección con un contexto distinto del que los escribió. Cada incremento termina con una firma de aceptación del proyecto. Las órdenes de este flujo (`discuss-phase`, `ui-phase`, `plan-phase`, `execute-phase`, `verify-work` y `code-review`), junto con `pause-work` y `resume-work` para retomar el trabajo entre sesiones, se usaron de verdad durante el proyecto.

3.2. Planificación viva y trazabilidad

La cadena de artefactos que produce cada paso vive en el árbol `.planning/` del repositorio, que actúa como la memoria de trabajo compartida entre el autor y los agentes. `PROJECT.md` recoge el encuadre general del proyecto y las decisiones de producto que no cambian de una fase a otra. `REQUIREMENTS.md` mantiene el catálogo de requisitos con su identificador, su estado y la fase que lo cierra, de forma que un

requisito se puede seguir desde que se declara hasta que queda marcado como completo. ROADMAP.md descompone el proyecto en fases con sus planes y su progreso. Las fases son las unidades de trabajo del *roadmap*: están numeradas en orden (con decimales, como la 01.1, cuando se insertó una posterior) y la memoria las cita por ese número, por ejemplo la Fase 2 para el laboratorio de evaluación. STATE.md conserva un resumen del punto en el que se encuentra el trabajo, con referencia al último commit relevante, pensado para que una sesión nueva, humana o de agente, pueda retomar el hilo sin releer todo el historial. Cada fase añade además, dentro de .planning/phases/, un par de documentos por plan: un PLAN.md que describe qué se va a hacer y cómo se va a verificar y un SUMMARY.md que el agente ejecutor redacta al terminar, con lo que se hizo, las desviaciones respecto al plan original y la evidencia que lo respalda. Esta cadena de documentos es la que permite responder, meses después, a la pregunta de por qué existe una línea de código concreta: se remonta al plan que la motivó, a la verificación que la aceptó y al requisito que la justificaba, sin depender de la memoria de nadie.

La Tabla 3.1 enumera los artefactos principales del árbol y su función.

Artefacto	Función
PROJECT.md	Definición del producto, valor central, requisitos activos y fuera de alcance.
REQUIREMENTS.md	Catálogo de requisitos con identificador estable y matriz de trazabilidad a evidencia.
ROADMAP.md	Incrementos, objetivos, criterios de éxito y progreso.
STATE.md	Estado actual, posición, decisiones acumuladas y continuidad de sesión.
phases/<incremento>/<plan>-PLAN.md	Alcance y criterios de aceptación de un plan, antes de implementar.
phases/<incremento>/<plan>-SUMMARY.md	Lo realmente ejecutado, desviaciones y evidencias, al cerrar el plan.
phases/<incremento>/<incremento>-VERIFICATION.md	Verificación independiente del objetivo del incremento.
phases/<incremento>/deferred-items.md	Hallazgos fuera de alcance, enrutados a trabajo posterior.

Tabla 3.1: Artefactos principales del árbol .planning/.

La trazabilidad se apoya en tres mecanismos. El primero es la matriz de REQUIREMENTS.md, que registra el estado de cada requisito y la evidencia que lo cierra, de modo que cualquier requisito se puede seguir hasta el trabajo que lo entrega y hasta la prueba que lo respalda. El segundo es la correspondencia entre planes e incidencias: cada plan tiene una incidencia (*issue*) abierta en el repositorio, que los mensajes de commit referencian con Refs #N mientras el plan avanza y que

se cierra con Closes #N cuando el SUMMARY.md confirma que quedó ejecutado, integrado y verificado. Así el historial de incidencias muestra, sin abrir el árbol .planning/, qué trabajo está cerrado y con qué evidencia. El tercero es el registro de agentes descrito en la Sección 3.3, que ata cada artefacto a la acción que lo produjo mediante un hash de contenido. Entre los tres, una decisión de la memoria se puede recorrer hacia atrás hasta su plan, su requisito y su discusión; hacia delante llega hasta la prueba y la firma que la verifican.

Además del registro de agentes, el proyecto conserva dos registros de decisión. Los ítems diferidos, en deferred-items.md, recogen los hallazgos fuera de alcance descubiertos durante la ejecución, con su motivo y su destino. Los registros de decisión de arquitectura, en docs/adr/, documentan cada decisión material con su contexto, sus alternativas, su decisión, su evidencia, sus consecuencias y su reversibilidad. El Capítulo 5 resume los nueve registros de decisión de arquitectura vigentes.

El árbol .planning/ es la fuente de verdad operativa, pero no está pensado para explorar cómo se relacionan las ideas entre sí. Para eso, el proyecto mantiene además un *vault* de Obsidian, ideas-vault/, una colección de notas en Markdown enlazadas entre sí mediante referencias internas que Obsidian representa como un grafo navegable. Cada nota recoge un concepto (una decisión de diseño, un requisito, un algoritmo, una fase); sus enlaces señalan de qué otras notas depende o a cuáles afecta, de modo que retomar un concepto después de semanas sin tocarlo no exige reconstruir el contexto desde cero: basta con abrir su nota y seguir sus enlaces. La Figura 3.2 muestra el grafo real del vault de SavePoint en el momento de escribir esta memoria, generado a partir de los enlaces existentes entre sus notas, no como una ilustración esquemática.




Figura 3.2: Grafo del vault de Obsidian de SavePoint ([ideas-vault/](#)), coloreado por categoría de nota. Se muestra la componente conexa principal, ciento veintitrés notas de las ciento cincuenta que contiene el vault; el resto enlaza solo entre sí en subgrafos pequeños y aislados. Los nodos de mayor tamaño, como 00 - Índice o los mapas de investigación y de datos, son las notas con más enlaces entrantes y salientes.

El vault y el árbol `.planning/` cumplen papeles distintos y deliberadamente no redundantes. El árbol de planificación es normativo: fija alcance, criterios de aceptación y evidencia; de él depende que un plan se dé o no por cerrado. El vault es descriptivo: enlaza conceptos con las fuentes canónicas que los sustentan (un ADR, un requisito, una fase) para que se puedan explorar sus relaciones de forma visual, pero nunca sustituye a las pruebas, a los hashes ni a los artefactos versionados que certifican una decisión. Esta separación se aplicó también a la propia redacción de esta memoria: antes de escribir varios de los capítulos que siguen, resultó más rápido navegar el grafo del vault para recuperar cómo encajaban entre sí conceptos ya explorados en sesiones distintas, semanas atrás, que releer el historial completo de decisiones desde cero.

3.3. Agentes especializados y contrato de contexto

El proyecto se desarrolló con asistencia sistemática de los agentes especializados que define GSD. Conviene delimitar desde el principio el reparto de responsabilidades, que la Sección 3.8 retoma: los agentes ejecutan, mientras que la definición del alcance, los criterios de aceptación, la revisión de cada entrega y la decisión final son del proyecto. El uso de agentes se describe aquí como una metodología de trabajo que se diseñó, dirigió y evaluó, no como una coautoría.

El método de la Sección 2.3 se instrumenta en SavePoint con tres mecanismos. El primero es el aislamiento del contexto: el trabajo se descompone en tareas atómicas, cada una ejecutada por una instancia nueva del agente con la ventana limpia, y la información viaja entre tareas por los ficheros persistentes del árbol .planning/ (Sección 3.2), de modo que una interrupción, un límite de sesión o un cambio de día no hacen perder el hilo. El segundo es la especialización de esas instancias en los papeles de la Tabla 3.2: quien planifica, quien implementa y quien verifica son instancias independientes, de modo que la verificación no hereda la confianza del código recién escrito, igual que en un equipo humano se separan el desarrollo y la revisión.

Rol	Responsabilidad y límite
gsd-phase-researcher	Recopila y sintetiza evidencia para planificar un incremento. Propone; etiqueta fuente, evidencia o supuesto.
gsd-ui-researcher / gsd-ui-checker	Convierten los requisitos en un contrato de diseño y lo validan. La comprobación automática de accesibilidad no sustituye la revisión humana.
gsd-planner	Divide el alcance en tareas verificables. Propone secuencia y gates; no declara terminado el producto.
gsd-executor	Implementa, prueba y registra correcciones en una copia de trabajo aislada, con commits atómicos. No se presenta como verificación independiente.
gsd-verifier	Verifica el objetivo del incremento de forma independiente y escribe el informe de verificación.
gsd-code-reviewer	Revisa todo el repositorio en busca de defectos con un contexto propio, distinto del de la implementación.

Tabla 3.2: Subagentes empleados y su responsabilidad.

El tercer mecanismo traslada ese aislamiento al sistema de ficheros mediante *worktrees* de Git, copias de trabajo independientes que comparten el mismo historial de repositorio pero permiten que varios agentes ejecutores avancen en paralelo sin pisarse los cambios. El ciclo de un ejecutor es siempre el mismo: se crea un *worktree* nuevo para el plan que le corresponde, el agente trabaja y hace sus *commits* dentro de esa copia aislada, al terminar se integra el resultado en la rama principal mediante una fusión sin avance rápido (`merge --no-ff`), que conserva

visible en el historial el conjunto de cambios de ese plan como una unidad; por último, se limpia el *worktree*. Cuando varios planes de una misma fase declaran el mismo requisito, la orquestación añade además una comprobación de que todos esos planes tienen ya su `SUMMARY.md` antes de marcar el requisito como cerrado, para que ningún requisito quede completo mientras una de sus partes sigue pendiente en otro plan.

Además de los subagentes, el repositorio versiona *skills*: procedimientos empaquetados que un agente puede invocar para una tarea concreta y repetible, como revisar código con un criterio fijo o preparar una entrega. Al vivir dentro del repositorio, junto al código que producen, las *skills* quedan sujetas al mismo control de versiones, a la misma revisión y al mismo historial que cualquier otro artefacto del proyecto. El entorno de trabajo del agente deja así de ser una configuración personal invisible para convertirse en parte del entregable: cualquiera que clone el repositorio dispone del mismo procedimiento que se empleó durante el desarrollo, no solo del resultado final.

Todo agente que empieza a trabajar en el repositorio, sea la herramienta que sea, lee primero un conjunto fijo de ficheros de instrucciones que actúan como su contrato de contexto: `AGENTS.md`, `CLAUDE.md` y `.github/copilot-instructions.md` declaran las reglas que cualquier asistente debe seguir en este proyecto, mientras que `CONVENTIONS.md` fija las convenciones concretas de idioma, de nomenclatura y de flujo de trabajo con incidencias. Un ejemplo transversal de regla en ese contrato es la convención de idioma del proyecto: la documentación de este TFG se escribe en español, el código y sus comentarios se escriben en inglés. Esa regla se aplica sin excepción con independencia de qué herramienta esté trabajando en cada momento, precisamente porque vive en un fichero que todas ellas leen al empezar, en lugar de depender de que alguien la recuerde y la repita en cada conversación.

Sobre ese mismo contrato se apoyan los ficheros de memoria del agente, que sobreviven entre sesiones: cuando un error del agente o una corrección del proyecto tiene valor general, se destila en una regla que se relee al iniciar cada tarea, de modo que el fallo no se repite. El proyecto acumuló varias reglas de este tipo a partir de incidencias reales:

- La lista de identificadores de Wikidata escrita a mano en el guion de adquisición contenía entidades que no eran videojuegos. La regla derivada obliga a verificar en vivo cualquier identificador de Wikidata antes de usarlo, sin confiar en la memoria ni en un commit anterior.
- El primer intento de cargar el catálogo de IGDB junto al corpus de Wikidata abortó por una colisión de *slug* de plataforma. La corrección enseñó al importador a reconciliar una plataforma existente por *slug*, nombre e inserción dentro de un savepoint, en lugar de fallar.
- Los enganches de GSD fallaban en Windows por un problema de shell. Detectarlo y corregirlo pronto evitó que el resto del trabajo tropezara con lo mismo.
- Sin un montaje enlazado de Docker y sin cargar el módulo de configuración de Django dentro del contenedor, toda verificación posterior habría probado

una imagen obsoleta o habría fallado al arrancar. Corregir ambos al detectarlos evitó que el trabajo siguiente chocara con la misma pared.

El componente más distintivo del proceso es el registro de agentes, `docs/methodology/agent-ledger.jsonl`, un fichero de solo anexo con un objeto por línea. Cada entrada lleva una marca de tiempo, un tipo, el actor, el objetivo, las entradas y salidas referenciadas por ruta relativa y hash SHA-256, las herramientas empleadas sin sus secretos, el resultado y las limitaciones declaradas. El tipo es uno de tres: `proposal` para una propuesta de agente, `automated-check` para una comprobación determinista y `author-decision` para una decisión humana, que siempre identifica al actor como persona. El registro contiene veinticinco entradas. El `gate scripts/check-evidence.ps1` valida su esquema, sus tipos, sus actores, sus rutas, sus hashes y su cobertura, probando primero con entradas inválidas antes de dar por buena una ejecución limpia.

El registro es una convención auditable, no un almacén criptográficamente inmutable: Git conserva las revisiones y el gate detecta corrupción de referencias en el estado actual, pero un actor con permiso de escritura podría reescribir el historial. Para la evidencia final se firma o etiqueta el commit correspondiente. El registro es honesto sobre sus propios huecos: donde un artefacto histórico resultó irrecuperable, la entrada lo declara en sus campos de entradas no verificables y de limitaciones en lugar de ocultarlo o falsearlo. También registra que el proyecto usó más de un entorno de agente, con modelos distintos en el trabajo inicial y en el posterior, con la advertencia de que un nombre de modelo no basta para reproducir una salida probabilística: la evidencia reproducible son los artefactos versionados, los hashes, los comandos y las decisiones humanas.

Los mensajes de commit siguen el estilo de *Conventional Commits* y se escriben en inglés.

3.4. Planificación del laboratorio de evaluación

La Fase 2 se planificó como el puente entre la demostración de producto y la evaluación reproducible. Su objetivo no era añadir una pantalla aislada, sino fijar las condiciones que permiten afirmar algo sobre un recomendador: qué obras entran en el corpus, qué significan las valoraciones, qué usuarios se simulan, cómo se construyen los candidatos y con qué métricas se comparan las listas. Las decisiones metodológicas se tomaron antes de cualquier ejecución de laboratorio y se conservaron en el directorio de planes de la fase.

El orden no es accidental. El corpus y el snapshot preceden al protocolo; el protocolo precede a la generación de usuarios y a la implementación de variantes; y solo entonces se puede ejecutar una comparación con garantías de que todos los algoritmos han recibido la misma partición y el mismo conjunto de candidatos. Una tarea completada ha superado las verificaciones de su contrato, pero no demuestra una superioridad algorítmica.

Las decisiones que bloquean una comparación posterior quedaron congeladas

en `docs/methodology/protocol.json` y en `docs/methodology/evaluation-protocol.md`: el corpus, el significado de las valoraciones, la población sintética, la relevancia, el conjunto de candidatas y las métricas. Esta sección solo recoge cómo se planificó esa congelación; el contenido de cada decisión se describe donde se aplica. El corpus y los ratings, en la Sección 6.2; el diseño del laboratorio, en la Sección 5.6; y el protocolo con el que se publicaron los resultados, en la Sección 7.1.

3.5. Planificación temporal

El trabajo se planificó como una sucesión de incrementos verticales, cada uno utilizable y verificado antes de abordar el siguiente, en lugar de un calendario cerrado de tareas fijado desde el principio. El desarrollo se organizó en seis iteraciones a lo largo de cuatro meses, del 2 de junio al 30 de septiembre de 2026, agrupadas alrededor de los hitos de la Tabla 3.3.

Tabla 3.3: Lista de hitos del trabajo.

Hito	Fecha
H0 — Aprobación de la propuesta y arranque del repositorio	02/06/2026
H1 — Demostración pública de tres días en producción (Fase 1)	12/06/2026
H2 — Catálogo a escala real e interfaz rediseñada (Fase 01.1)	03/07/2026
H3 — Contrato de evaluación offline congelado (Fase 2)	24/07/2026
H4 — Recomendadores de contenido, colaborativo e híbrido implementados	14/08/2026
H5 — Publicación de resultados v15 con significación estadística	12/09/2026
H6 — Flujos de colección, relaciones de amistad y endurecimiento cerrados	14/09/2026
H7 — Memoria del TFG completa, lista para defensa	30/09/2026

La Figura 3.3 sitúa las iteraciones y los hitos en el calendario.

La **Iteración 1** (2 al 14 de junio) cubrió el estudio previo: revisión de productos de referencia, comparación de fuentes de datos de videojuegos y sus licencias, y las primeras decisiones de arquitectura (ADR-001 y ADR-002); cerró con un entorno de desarrollo reproducible en Docker Compose. La **Iteración 2** (15 de junio al 3 de julio) entregó el primer incremento de producto bajo una restricción explícita de tres días para una demostración pública visible, con un catálogo reducido, una cuenta y la recomendación por popularidad; a continuación amplió el catálogo a escala real e incorporó el rediseño de la interfaz. La **Iteración 3** (4 al 24 de julio) congeló el contrato de evaluación offline: corpus, población sintética, métricas y protocolo, antes de escribir ningún algoritmo de recomendación avanzado. La **Iteración 4** (25 de julio al 14 de agosto) implementó las tres familias de recomendación (contenido, colaborativo e híbrido) y sus dieciséis variantes. La **Iteración 5** (15 de agosto al 13




Figura 3.3: Calendario de las iteraciones y de los hitos H0 a H7 del trabajo.

de septiembre) cerró los flujos completos de colección y portabilidad, las relaciones de amistad y el endurecimiento de seguridad; ejecutó también la publicación final de resultados (v15) descrita en el Capítulo 7. La **Iteración 6** (14 al 30 de septiembre) se dedicó por completo a la redacción, revisión y cierre de esta memoria.

3.6. Estimación de esfuerzo y presupuesto

El proyecto no llevó un registro de horas minuto a minuto por tarea, de modo que la estimación de esfuerzo que sigue se reconstruye a partir de la duración de cada iteración y de la carga de trabajo declarada de un estudiante que compagina el TFG con otras obligaciones académicas, en torno a veinticinco horas semanales durante las diecisiete semanas del proyecto. Tomando como unidad el bloque de trabajo, no el incremento, la Tabla 3.4 reparte esas horas entre las grandes áreas del trabajo.

Tabla 3.4: Estimación de horas por bloque de trabajo.

Bloque	Horas estimadas
Análisis, requisitos y diseño	60
Infraestructura reproducible y despliegue	35
Implementación de producto (backend y frontend)	120
Adquisición y gobierno de datos	40
Algoritmos de recomendación y protocolo de evaluación	90
Pruebas, verificación y revisión	45
Redacción de la memoria	50
Total	440

El coste directo se calcula sobre esas 440 horas con una tarifa de referencia de

un perfil junior de ingeniería del software en España, 14,00€/hora, una cota conservadora frente al coste real de contratación de un perfil equivalente. El coste material recoge la amortización proporcional del equipo personal empleado (un portátil de gama media, con una vida útil estimada de cuatro años, del que este trabajo consume cuatro meses); no se incluye ningún coste de infraestructura en la nube, porque la topología de despliegue público se diseñó explícitamente de coste cero (ADR-005, Sección 6.6). El coste indirecto recoge la cuota proporcional de cuatro meses de electricidad y conexión a internet atribuible al proyecto. La Tabla 3.5 resume el presupuesto total.

Concepto	Coste (€)
Coste directo (440 h a 14,00€/h)	6.160,00
Coste material (amortización de equipo, 4 meses)	75,00
Costes indirectos (electricidad y conexión, 4 meses)	180,00
Presupuesto total	6.415,00

Tabla 3.5: Estimación de esfuerzo y presupuesto del proyecto.

Estas cifras son una estimación reconstruida a posteriori, no una medición registrada durante el desarrollo; así debe entenderse cualquier comparación futura entre coste estimado y coste real.

3.7. Riesgos y mitigaciones

La Tabla 3.6 recoge los riesgos que se identificaron y cómo se mitigaron o se mantienen bajo vigilancia.

Riesgo	Mitigación
Restricción de tres días del primer incremento público	Alcance de demostración deliberadamente estrecho: catálogo pequeño, una cuenta y recomendación por popularidad.
Términos legales de las fuentes de datos	Confirmación caso por caso: corpus de Wikidata bajo dominio público, términos de IGDB registrados textualmente y reconciliados en un registro de decisión.
Volumen de IGDB en una importación larga	Importador reanudable por cursor de identificador, con checkpoint tras cada lote y resistencia probada a una interrupción.
Portadas por enlace directo a un tercero	Ventana de retención de treinta días asumida; ausencia o fallo de una portada cae a un marcador propio.
El protocolo de evaluación debe congelarse antes de comparar recomendadores	El heurístico de géneros del sistema se declaró explícitamente fuera de esa comparación desde el principio; la comparación en sí se congeló y se ejecutó más tarde, como recoge el Capítulo 7.
Errores del agente en trabajo dado por bueno	Verificación de objetivos independiente y revisión de código de todo el repositorio con contexto propio.
Despliegue no conectado a datos reales	Decisión registrada del proyecto de posponer esa conexión al final del proyecto; el entorno local reproducible es la vía de demostración.

Tabla 3.6: Riesgos identificados y sus mitigaciones.

3.8. Lecciones aprendidas y valoración de la metodología

El trabajo dejó varias lecciones de ingeniería que conviene recoger. La primera tiene que ver con el despliegue. La topología pasó de un único proveedor con predespliegue para las dos imágenes de contenedor a tres servicios gratuitos coordinados, al chocar la restricción de coste cero con el modelo de un solo proveedor. La decisión y sus consecuencias quedaron documentadas en un registro de decisión de arquitectura, de modo que la diferencia entre el despliegue público y el entorno local es una elección deliberada y no una divergencia de comportamiento.

La segunda es de higiene del propio proceso: un gate de evidencia llegó a estar en rojo en la rama principal por un problema de fin de línea y por registros de decisión escritos en inglés antes de fijarse la convención de idioma. Corregirlo en cuanto se detectó evitó que el resto del trabajo arrastrara un gate poco fiable. Estas incidencias, junto con otras menores, quedaron registradas en los resúmenes de plan.

El enfoque produjo beneficios concretos y observables en el proyecto, junto con límites que conviene declarar con la misma franqueza. El alcance se mantuvo bajo control a lo largo de sucesivos incrementos, sin que el trabajo de uno se filtrara en otro, y cada cambio quedó trazado hasta su plan, su requisito y su evidencia. Las revisiones de código con contexto independiente encontraron dieciséis hallazgos reales, descritos en la Sección 6.5, que se corrigieron por completo, incluidos defectos de seguridad en trabajo ya dado por bueno. El trabajo se pudo reanudar sin pérdida de hilo tras interrupciones y límites de sesión, porque el estado vivía en ficheros y no en una conversación, y el propio proceso de ingeniería quedó reproducible, no solo el producto: un tercero puede clonar el repositorio y reconstruir la historia de decisiones a partir del árbol de planificación, los registros de decisión, el registro de agentes y los gates de evidencia.

El enfoque depende, sin embargo, de la calidad de la especificación escrita: un plan ambiguo produce una ejecución ambigua. Mantener la disciplina de planificación, verificación y registro tiene un coste de tiempo notable para un TFG individual, y los agentes cometieron errores que hubo que detectar y corregir, algunos de ellos recogidos en la Sección 3.3. Un agente no es un evaluador independiente de su propia propuesta, del mismo modo que un hash prueba identidad de bytes, no veracidad ni calidad; por eso el enfoque no sustituye el juicio del proyecto sobre arquitectura, alcance y aceptación, sino que lo enmarca. Existe un informe de uso de herramientas de asistencia, independiente y posterior, que cubre la transparencia de su empleo; esta memoria ni lo suple ni lo contradice.

Los capítulos siguientes aplican ese método al análisis, al diseño y a la construcción del sistema.

4. Análisis del problema

Este capítulo recoge el análisis de requisitos del proyecto. Presenta los actores del sistema, el modelo de dominio que sostiene los requisitos de información, los requisitos funcionales y no funcionales, las reglas de negocio, los casos de uso y la matriz de trazabilidad que enlaza cada requisito con su evidencia. Los requisitos se identifican con códigos estables tomados de `.planning/REQUIREMENTS.md`, de modo que la matriz de trazabilidad de este capítulo y la del repositorio coinciden. Los requisitos abarcan por igual las dos caras del trabajo: la plataforma de catalogación y la evaluación de recomendadores que se apoya en ella.

4.1. Actores del sistema

El sistema distingue dos actores, que enumera la Tabla 4.1. Para que el tribunal pueda recorrer el sistema sin registrarse, el entorno incluye una cuenta de usuario ya preparada, que es una cuenta normal con sus datos y no un actor distinto.

Actor	Descripción	Estado
Visitante	Persona no autenticada que consulta el catálogo, la ficha de un juego y la recomendación por popularidad, y que puede registrarse.	Activo
Persona usuaria	Titular de una cuenta registrada que inicia sesión y gestiona su lista de pendientes, valora juegos, inventaría copias y se relaciona con sus amigos.	Activo

Tabla 4.1: Actores del sistema.

4.2. Requisitos de información: modelo de dominio

El modelo de dominio distingue tres áreas: el catálogo, la biblioteca personal y las cuentas. La Figura 4.1 las representa junto con las tablas del laboratorio de evaluación, que describe la Sección 5.6; los párrafos siguientes describen las entidades de las tres primeras.




Figura 4.1: Modelo de dominio de SavePoint, agrupado por catálogo, biblioteca personal, cuentas y amistades, y laboratorio de evaluación. Cada flecha parte de la entidad que contiene la clave foránea y apunta a la entidad que referencia; la flecha de doble punta indica una relación de muchos a muchos y la discontinua, una referencia opcional. De las copias en propiedad solo se dibujan sus referencias a la versión de lanzamiento y a la edición; IgdbImportRun y AssetAttribution se omiten de la figura y se describen en el texto.

En el catálogo, la entidad central es la obra (GameWork), la identidad canónica de un título de videojuego con independencia de la plataforma y de la edición. Cada obra puede tener varias publicaciones (GameRelease), una por plataforma (Platform). Cada publicación puede tener a su vez varias ediciones (Edition). Los géneros (Genre) se asocian a la obra mediante una relación de muchos a muchos. Los alias bilingües (GameAlias) sostienen la búsqueda tolerante. El contenido relacionado (RelatedContent) enlaza contenido descargable (DLC) y expansiones con su obra padre. La procedencia de cada obra vive en SourceRecord, con la fuente, el identificador de origen, la licencia, la fecha de recuperación y un hash del contenido normalizado. La atribución de cada portada revisada individualmente vive en AssetAttribution, cuya marca de portada permitida está a falso por defecto. El progreso de una importación de IGDB se registra en IgdbImportRun, con el cursor de identificador y el estado.

En la biblioteca personal, la entrada de biblioteca (LibraryEntry) representa la relación entre una persona usuaria y una obra, con su estado en la lista de pendientes y su valoración. El historial de transiciones de estado

(StatusTransition) es un registro de solo anexo. Las copias en propiedad (OwnedCopy) representan cada ejemplar, físico o digital, con su formato, su publicación y su edición.

En las cuentas, el proyecto usa directamente el modelo de usuario de Django (User), al que se asocian la biblioteca personal y las relaciones de amistad. Las solicitudes (FriendshipRequest), las amistades aceptadas (Friendship) y los bloqueos (Block) son entidades que referencian a dos usuarios.

La Tabla 4.2 enlaza cada área del modelo con los requisitos de información que satisface.

Área	Requisito de información	Códigos
Catálogo	Identidad canónica independiente del proveedor de enriquecimiento.	CAT-04
Catálogo	Registro de fuente, licencia, fecha de recuperación y hash por obra.	DATA-02
Catálogo	Metadatos de plataforma, género, edición y fechas de fuentes aprobadas.	CAT-05
Biblioteca	Estado de la lista de pendientes por persona y obra.	LIB-01
Biblioteca	Valoración con escala consistente.	LIB-02
Biblioteca	Copias en propiedad con formato, plataforma y edición.	INV-01, INV-02
Cuentas	Registro e inicio de sesión de las personas usuarias.	AUTH-01

Tabla 4.2: Áreas del modelo de dominio y requisitos de información asociados.

4.3. Requisitos funcionales y casos de uso

La Tabla 4.3 recoge los requisitos funcionales considerados en el análisis, con su estado real. Los marcados como completos tienen evidencia en las firmas de aceptación.

La Figura 4.2 presenta el diagrama de casos de uso del sistema tal como se analizó al inicio del proyecto.

La Tabla 4.4 describe cada caso de uso con su actor principal y el requisito funcional que satisface.

4.4. Requisitos de la evaluación de recomendadores

La planificación posterior a la primera demostración añadió requisitos que no se pueden validar únicamente recorriendo la interfaz. DATA-03 y DATA-06 exigen una frontera de corpus gobernada, reversible y versionada, con checksum, diccionario, informe de calidad y muestra determinista. DATA-05, DATA-07 y DATA-08 exigen

Código	Requisito funcional	Estado
AUTH-01	Iniciar y cerrar sesión en una cuenta controlada.	Completo
SOCIAL-03	Buscar a otra persona por su alias exacto y gestionar solicitudes de amistad, amistades y bloqueos.	Completo
SOCIAL-04	Consultar la colección, las listas y los comentarios de un amigo aceptado; quien no es amigo no ve nada de la cuenta.	Completo
CAT-01	Buscar videojuegos por título.	Completo
CAT-02	Filtrar y ordenar el catálogo por metadatos disponibles.	Completo
CAT-03	Ficha de detalle de cada juego con sus datos y su procedencia.	Completo
CAT-04	Identificadores canónicos que no dependen de la API de enriquecimiento.	Completo
CAT-06	Catálogo usable con datos locales si la API no está disponible.	Completo
LIB-01	Marcar un juego como pendiente, jugando, completado o abandonado.	Completo
LIB-02	Valorar un juego con una escala consistente.	Completo
INV-01	Registrar varias copias de la misma obra.	Completo
INV-02	Registrar formato, plataforma y edición de cada copia.	Completo
INV-05	Las notas privadas y los detalles de compra nunca aparecen en las proyecciones que ven los amigos.	Completo
DATA-01	Conjunto de datos estable, citable y legalmente adecuado.	Completo
DATA-02	El conjunto registra versión, licencia, URL de origen, fecha y hash.	Completo
DATA-04	API de enriquecimiento elegida mediante comparación documentada.	Completo
REC-02	Baseline de recomendación por popularidad.	Completo
REC-10	Página de recomendaciones por géneros según la actividad propia.	Completo
REC-03 a REC-09	Recomendadores basados en contenido, colaborativos e híbridos, con explicaciones y arranque en frío.	Completo (Fases 2-4)
PORT-01 a PORT-04	Exportación e importación de colección, valoraciones y listas.	Completo (Fases 5 y 7)

Tabla 4.3: Requisitos funcionales considerados en el análisis del sistema.

Id	Caso de uso	Actor	Requisito
CU-1	Buscar un juego por título	Visitante	CAT-01
CU-2	Consultar la ficha de un juego y su procedencia	Visitante	CAT-03
CU-3	Filtrar y ordenar el catálogo	Visitante	CAT-02
CU-4	Ver la recomendación por popularidad	Visitante	REC-02
CU-5	Registrarse como persona usuaria	Visitante	AUTH-01
CU-6	Iniciar y cerrar sesión	Persona usuaria	AUTH-01
CU-7	Cambiar el estado de un juego en la lista de pendientes	Persona usuaria	LIB-01
CU-8	Valorar un juego	Persona usuaria	LIB-02
CU-9	Registrar una o varias copias en propiedad	Persona usuaria	INV-01, INV-02
CU-10	Abrir la página de recomendaciones por afinidad de géneros	Persona usuaria	REC-10
CU-11	Gestionar solicitudes de amistad, amistades y bloqueos	Persona usuaria	SOCIAL-03
CU-12	Consultar la colección de un amigo	Persona usuaria	SOCIAL-04
CU-13	Comentar un juego, con el comentario visible solo para los amigos	Persona usuaria	LIB-03, SOCIAL-04

Tabla 4.4: Casos de uso del sistema.




Figura 4.2: Diagrama de casos de uso del sistema, por actor principal. Cada línea une un actor con los casos de uso que ejecuta.

importar ratings con procedencia, reconciliar fuentes externas sin fuzzy matching y conservar snapshots inmutables por versión.

EVAL-01, EVAL-02 y EVAL-03 fijan la comparación sobre la misma partición, los mismos candidatos y las mismas exclusiones. EVAL-09 y EVAL-10 añaden usuarios sintéticos parametrizados y obligan a separar la evidencia simulada de cualquier afirmación sobre usuarios reales. DOC-04 exige que el protocolo, las métricas, las semillas, las versiones y las amenazas a la validez queden escritos antes del resultado.

En recomendación, REC-01 exige un baseline aleatorio reproducible y REC-03 vectores de contenido dispersos, perfil de usuario y similitud. REC-06 a REC-09 describen el cold-start, las exclusiones, la explicación por contribuciones y el DTO versionado de las variantes comparadas.

4.5. Requisitos no funcionales y reglas de negocio

Los requisitos no funcionales del sistema se agrupan en cinco familias. La *reproducibilidad* exige que el sistema arranque de forma reproducible en un entorno local documentado, con las dependencias fijadas a versión exacta (QUAL-02, OPS-02). La *legalidad y procedencia de datos* exige que cada dato del catálogo conserve su fuente, su licencia y su fecha de recuperación, con la elección de fuentes documentada junto con sus términos (DATA-01, DATA-02, DATA-04,

DATA-08). La *accesibilidad y el diseño responsive* exigen que los flujos principales funcionen con teclado y en anchuras de escritorio y de móvil, verificables frente a las Pautas de Accesibilidad para el Contenido Web (WCAG) 2.2 en nivel AA [19] (QUAL-03). La *seguridad* exige que ningún secreto aparezca en el control de versiones, en los paquetes del navegador, en los registros ni en artefactos públicos. También exige que las acciones de cambio de estado estén protegidas contra falsificación de petición en sitios cruzados (SEC-02, SEC-04). La *calidad visual de producto* exige que la interfaz presente una densidad, una tipografía y un tratamiento de la imagen propios de un producto de catalogación, no de un prototipo utilitario (QUAL-05).

La Tabla 4.5 recoge las reglas de negocio que gobiernan el comportamiento del sistema.

Regla	Enunciado
RN-1	La identidad de una obra es un identificador interno propio; el identificador del proveedor externo se guarda solo como procedencia.
RN-2	El contenido descargable y las expansiones se muestran dentro de la página de su obra padre, nunca como resultado independiente del catálogo ni como entrada de biblioteca.
RN-3	Los detalles privados de propiedad, como notas y datos de compra, nunca aparecen en ninguna proyección que vea otra persona.
RN-4	La valoración se almacena como un entero de medias estrellas entre uno y diez; nunca como un número en coma flotante.
RN-5	La recomendación por popularidad se calcula a partir de las señales de popularidad importadas de IGDB y nunca se presenta como personalizada.
RN-6	La recomendación por afinidad de géneros refleja solo la actividad de la persona autenticada y nunca cae al baseline de popularidad; sin historial suficiente, muestra un estado de bienvenida.
RN-7	Registrar de nuevo una copia con la misma clave de idempotencia devuelve la copia existente en lugar de crear un duplicado.
RN-8	Ninguna cuenta es pública: solo su titular y sus amigos aceptados acceden a su colección, sus listas y sus comentarios, y una persona sin sesión no ve ninguna cuenta.
RN-9	El acceso a IGDB queda confinado a un comando de gestión fuera de línea; ninguna petición de usuario llama a un proveedor externo.

Tabla 4.5: Reglas de negocio.

4.6. Trazabilidad de requisitos

De los ochenta y ocho requisitos identificados en el análisis, ochenta y seis están completos, con evidencia verificable en docs/verification/ o en las firmas de aceptación por fase. Entre ellos están las tres familias de recomendación y su protocolo de evaluación offline, que desarrollan la Sección 5.5 y el Capítulo 7. Los

dos requisitos pendientes son parciales y pertenecen al mismo contrato de evaluación: repetir la comparación de algoritmos con varias semillas y retroproyectar sobre la ejecución v15 la captura de entorno y consumo de recursos. La Sección 8.2 los recoge como limitaciones declaradas.

La Tabla 4.6 recorre las dieciséis familias de requisitos del proyecto, con cuántos de cada una están completos y verificados frente a los que quedan pendientes. Cada fila es, en sí misma, una entrada de trazabilidad: el código de familia enlaza directamente con los identificadores individuales de `.planning/REQUIREMENTS.md`; el estado de cada uno de ellos remite a su vez a una firma de aceptación por fase o a un plan concreto en `docs/verification/`.

Tabla 4.6: Trazabilidad de requisitos de SavePoint, por familia.

Familia	Cubre	Completos	Total
AUTH	Autenticación y sesión	1	1
PROF	Perfil personal	3	3
CAT	Catálogo, búsqueda y filtrado	6	6
LIB	Biblioteca y valoración	4	4
INV	Inventario de copias	5	5
DATA	Procedencia y gobierno de datos	8	8
REC	Algoritmos de recomendación	10	10
EVAL	Protocolo y laboratorio de evaluación	10	12
SEC	Seguridad	8	8
OPS	Operaciones y copia de seguridad	5	5
QUAL	Calidad de producto y accesibilidad	5	5
DOC	Documentación y registro	6	6
AGENT	Metodología de ingeniería	6	6
PORT	Portabilidad de datos	4	4
PRIV	Privacidad	2	2
SOCIAL	Relaciones sociales	3	3
Total		86	88

Los dos pendientes pertenecen a la familia EVAL; ningún requisito completo depende de ellos para su propia verificación, de modo que ese trabajo futuro no invalida ninguna evidencia ya cerrada.

La Tabla 4.7 enlaza cada requisito entregado con la evidencia que lo respalda. La columna de evidencia remite a documentos del repositorio: firmas de aceptación en `docs/verification/`, registros de decisión en `docs/adr/` e informes de verificación en `.planning/phases/`.

Requisito	Evidencia
AUTH-01	phase-01-signoff.md; pruebas de accounts.
CAT-01, CAT-03, CAT-04, CAT-06	phase-01-signoff.md; catalogue-freeze.md.
LIB-01, LIB-02, INV-01, INV-02, INV-05	phase-01-signoff.md; pruebas de library.
DATA-01, DATA-02	catalogue-freeze.md; ADR-003.
REC-02	library/popularity.py; phase-01-signoff.md.
SEC-02, OPS-01, OPS-02, OPS-03	phase-01-signoff.md; check-secrets.ps1.
QUAL-03	phase-01-manual.md; 400 % de zoom y lector de pantalla pendientes.
DOC-01, AGENT-01, AGENT-02, AGENT-03	ADR-001 a 005; agent-ledger.jsonl.
DATA-04	ADR-006; igdb-api-probe.md.
CAT-02	01.1-VERIFICATION.md SC2; migración 0004.
REC-10	ADR-007; 01.1-VERIFICATION.md SC5.
QUAL-05	phase-01.1-signoff.md; revisión remota de capturas obtenidas durante la verificación.

Tabla 4.7: Matriz de trazabilidad de requisito a evidencia.

Este capítulo ha fijado qué debe hacer el sistema y con qué restricciones. El capítulo siguiente describe cómo se ha diseñado para cumplirlo.

5. Diseño y arquitectura

Este capítulo describe cómo se diseñó SavePoint para cumplir los requisitos del Capítulo 4. Presenta primero la arquitectura de la plataforma web y las decisiones que la sostienen, el modelo de datos, la API y la interfaz; después, el diseño de los algoritmos de recomendación que se construyen sobre ella y del laboratorio que los evalúa. Plataforma y algoritmos se diseñaron como un único sistema: la aplicación recoge y gobierna las señales que los algoritmos consumen, mientras que el laboratorio los compara sobre la misma base de datos y el mismo modelo de dominio.

5.1. Arquitectura del sistema

SavePoint es un monolito modular con dos ejecutables. El backend, en `apps/api/`, usa Django [20] con soporte a largo plazo (LTS) y Django REST Framework (DRF) [21] sobre PostgreSQL [22], con el mapeo objeto-relacional (ORM) de Django como interfaz de persistencia; sus módulos se separan por dominio (`catalogue`, `library`, `accounts`, `recommendations`, `evaluation`, `social`, `audit`), pero comparten despliegue y base de datos. El frontend, en `apps/web/`, es una aplicación Next.js [23] con React [24] y TypeScript en modo estricto, que renderiza en el servidor (SSR) las páginas de solo lectura; el navegador solo habla con Next.js, que reenvía las llamadas al backend (Sección 5.3). Los trabajos de recomendación y evaluación se ejecutan como comandos fuera de la petición HTTP: la aplicación publica sus resultados, pero no vuelve a calcular los resultados de la evaluación en el navegador. La Figura 5.1 representa esta arquitectura por capas, y el registro de decisión ADR-001 recoge el contexto completo de esta elección.




Figura 5.1: Arquitectura de SavePoint: el navegador solo habla con Next.js, que reescribe las llamadas hacia Django y DRF; los comandos de ingesta y el runner de evaluación escriben en PostgreSQL fuera de la petición HTTP.

Esa elección no fue automática. El dominio de SavePoint (obras, ediciones, copias, valoraciones, biblioteca) es relacional y con mucha escritura estructurada, el tipo de problema para el que Django y su ORM están pensados desde el principio, con autenticación, migraciones y validación ya resueltos en el propio marco de trabajo. Frente a alternativas más ligeras como FastAPI con SQLAlchemy, que habrían obligado a componer esas mismas piezas a mano, Django ofrece esa base madura sin coste adicional. Frente a servir la interfaz con plantillas de Django y HTMX, que habría evitado duplicar el contrato de datos entre backend y frontend, se prefirió un frontend Next.js separado porque el catálogo, la biblioteca y las recomendaciones necesitaban una interfaz más rica de lo que las plantillas del lado del servidor ofrecen con comodidad, sin perder por ello el renderizado en servidor que la accesibilidad y el primer pintado rápido piden. Una arquitectura de microservicios, por último, se descartó por su coste operativo y de trazabilidad en un proyecto de un único desarrollador: separar servicios solo se justifica cuando hay una necesidad medida que lo pida, no por anticipado.

PostgreSQL es la única base de datos de aplicación y de pruebas de integración, en desarrollo, en pruebas y en despliegue, sin sustituir nunca por una base más ligera en ningún entorno. El registro ADR-002 explica por qué: el modelo de datos de SavePoint depende de restricciones de unicidad, de transacciones y de búsqueda por similitud de texto que SQLite soporta de forma incompleta y que

una base documental como MongoDB no ofrece con la misma garantía de integridad relacional. Usar SQLite en local y PostgreSQL en producción, la solución más barata a corto plazo, se descartó explícitamente porque introduce una asimetría entre entornos que un banco de pruebas reproducible no se puede permitir: una consulta que funciona en SQLite y falla en PostgreSQL, o viceversa, sería un defecto del propio diseño experimental, no del código. Todo el sistema se levanta, en consecuencia, con Docker Compose a partir de los tres componentes de aplicación (base de datos, API y frontend), cada uno construido desde su propio fichero de Docker con versiones de dependencias fijadas; junto a ellos, Compose orquesta además un contenedor de *worker* independiente por cada variante de recomendación que la web publica (Sección 5.5.4), y no por las dieciséis que compara el laboratorio. Un trabajo cuyo objeto de estudio es la reproducibilidad de una comparación de algoritmos necesita, antes que nada, que el propio entorno de ejecución sea reproducible, y los contenedores eliminan esa variable en cualquier máquina que lo levante.

Para el despliegue público se adoptó una topología repartida entre tres proveedores gratuitos (Vercel para el frontend, Render para el backend y Neon para PostgreSQL), por una restricción de partida no negociable: coste cero, sin tarjeta de pago. La Sección 6.6, en el capítulo de implementación, desarrolla esta topología, sus límites conocidos y el estado actual del despliegue; el registro ADR-005 recoge la decisión completa.

5.2. Decisiones de arquitectura

Cada decisión de diseño con consecuencias materiales queda registrada en docs/adr/ como registro de decisión de arquitectura (ADR), con un formato fijo de contexto, alternativas, decisión, evidencia, consecuencias, reversibilidad y aprobación. La Tabla 5.1 resume el conjunto vigente; las secciones correspondientes citan cada registro donde es relevante. Cada registro es citable y reversible: los límites de dominio y las migraciones actúan como puntos de salida si una decisión se revisa.

Registro	Decisión y consecuencia principal
ADR-001	Monolito modular Django/DRF con frontend Next.js separado. Integridad y autenticación maduras, límites de dominio legibles, dos ejecutables con una sola arquitectura operable.
ADR-002	PostgreSQL 18.6 como única base de datos de aplicación y de pruebas de integración. Paridad entre entornos, integridad relacional, bloqueos y búsqueda de trigramas disponibles de forma reproducible.
ADR-003	Corpus congelado de Wikidata bajo dominio público y revisión de Commons por archivo. Evaluación repetible y procedencia visible, sin ninguna consulta a proveedores en tiempo de petición.
ADR-004	Sesión de Django y frontera del mismo origen. Las primitivas de sesión y de protección contra falsificación de petición en sitios cruzados las mantiene Django; ningún token accesible al código del navegador.
ADR-005	Docker Compose local y despliegue público repartido entre tres servicios gratuitos (Vercel, Render y Neon). Coste cero sin tarjeta, a cambio de que el frontend público no sea la misma imagen que la local.
ADR-006	IGDB como fuente del catálogo a escala real, con portadas por enlace directo. Cobertura real y modelado de género y plataforma de primera clase, a cambio de una obligación de atribución continua y de una licencia que es un acuerdo, no una dedicación al dominio público.
ADR-007	Heurístico determinista de afinidad por géneros para la página de recomendaciones. Entrega el requisito como página real y explicable, deliberadamente al margen de la comparación sistemática de recomendadores que la Sección 5.5 presenta más adelante.
ADR-008	Ratings externos gobernados por snapshot versionado, con enriquecimiento acotado desde RAWG.
ADR-009	Familias de algoritmos de recomendación y su ejecución como <i>workers</i> aislados. La web publica solo tres de las dieciséis variantes.

Tabla 5.1: Registros de decisión de arquitectura vigentes.

5.3. Modelo de datos, API y sesión

El modelo de datos, descrito en la Sección 4.2, sigue cuatro decisiones de diseño. La primera es que toda identidad canónica es un identificador único universal (UUID) interno, generado en la importación, con el identificador del proveedor guardado solo como procedencia; así, cambiar de proveedor o prescindir de él nunca obliga a reenumerar el catálogo (ADR-006, CAT-04). La segunda es que las restricciones y las transacciones viven también en la base de datos, no solo en la capa de aplicación: unicidad de entrada por persona y obra, unicidad de copia por clave de idempotencia, rango de la valoración por restricción de comprobación y un disparador que impide que el cursor de importación de IGDB retroceda. La tercera es la desnormalización deliberada de la fecha de primer lanzamiento y de la valoración agregada sobre la propia obra, para que el filtrado por año y por nota sea un recorrido de índice y no una agregación sobre cientos de

miles de publicaciones. La cuarta es un índice de trigramas sobre los alias normalizados, que sostiene la búsqueda tolerante por prefijo y por similitud.

La API es de estilo REST, servida por DRF bajo el prefijo `/api/`. Las respuestas de lista están paginadas. Las vistas de escritura y las de datos personales exigen sesión. Las anónimas de mayor coste llevan un límite de ritmo con ámbito propio. La Tabla 5.2 recoge los puntos de acceso principales.

Método y ruta	Acceso	Función
GET/api/catalogue/games/	Anónimo	Lista paginada con búsqueda, filtros, orden y facetas.
GET/api/catalogue/games/<slug>/	Anónimo	Ficha de una obra con su jerarquía y su procedencia.
GET/api/catalogue/sources/	Anónimo	Dataset, licencia, hash y política de portadas.
POST/api/accounts/login/, logout/	Anónimo	Inicio y cierre de sesión con protección de origen.
POST/api/accounts/register/	Anónimo	Registro de nuevas personas usuarias, con límite de ritmo.
GET/api/accounts/profiles/<alias>/	Sesión	Perfil de un amigo aceptado, por lista de campos permitidos.
GET/api/library/entries/	Sesión	Biblioteca de la persona autenticada.
POST/api/library/entries/<id>/status/,rating/,copies/	Sesión	Cambio de estado, valoración y alta de copias.
GET/api/library/popularity/	Anónimo	Baseline de popularidad a partir de las señales importadas de IGDB.
GET/api/recommendations/genre-taste/	Sesión	Recomendación por afinidad de géneros de la persona autenticada.

Tabla 5.2: Puntos de acceso principales de la API.

La proyección de un perfil que ve un amigo se construye con una lista explícita de campos permitidos, escrita a mano, en lugar de una serialización automática por introspección del modelo. Así, exponer un campo privado nuevo requiere una decisión explícita, que es el modo de fallo opuesto al de ocultarlo por olvido.

La autenticación sigue el diseño del registro ADR-004. Django emite y valida la sesión. El navegador solo llama a rutas del mismo origen de Next.js, que las reescribe hacia el backend mediante una variable de entorno visible únicamente en el servidor. Las cookies de sesión y de protección contra falsificación de petición en sitios cruzados (CSRF) viajan con ámbito del mismo origen, sin necesidad de compartir recursos entre orígenes con credenciales. Las mutaciones exigen el testigo CSRF. El cierre de sesión la invalida. Los redirectos posteriores al acceso solo aceptan rutas relativas del mismo sitio, revalidadas en el servidor. No hay

ningún testigo de tipo *bearer* accesible al código JavaScript del navegador.

El diseño mantiene dos fronteras explícitas. Ninguna cuenta es pública, de modo que solo los amigos aceptados acceden a su contenido, y el acceso a IGDB está confinado a un comando de gestión fuera de línea, sin que ninguna petición de usuario llame a un proveedor externo (RN-8 y RN-9 de la Tabla 4.5).

5.4. Diseño de la interfaz de usuario

El diseño de la interfaz se fijó en un contrato de diseño, 01.1-UI-SPEC.md, aprobado antes de implementar y validado por un subagente comprobador. El contrato define un sistema de tokens de variables CSS, con juegos completos para tema claro y tema oscuro, cuya selección se aplica en el servidor mediante una cookie para evitar el destello al cargar. Los componentes reutilizables incluyen la tarjeta de juego, las píldoras de estado y de nota, la valoración por estrellas, la imagen de portada con su marcador de reserva, la barra de filtros, el conmutador de tema y el selector de cuenta. Las Figuras 5.2 y 5.3 muestran la página de inicio en ambos temas.



Figura 5.2: Página de inicio con tema claro y sin sesión iniciada.



Figura 5.3: Página de inicio con tema oscuro y con sesión iniciada.

El contrato de diseño incluye una matriz de cobertura por superficie, con filas para el catálogo, el detalle, el registro y las recomendaciones, cada una con su verificación en escritorio, en móvil y de accesibilidad. El Capítulo 6 describe las rutas y los componentes concretos; la Sección 6.5 recoge su verificación.

5.5. Diseño de los algoritmos de recomendación

Esta sección detalla cómo SavePoint representa una obra y a una persona usuaria, qué señales intervienen en la puntuación de una candidata, con qué fórmulas y pesos exactos se combinan esas señales en cada uno de los dieciséis algoritmos comparados, qué respaldo en la literatura tiene cada una de esas decisiones y cuáles se descartaron y por qué. El Capítulo 7 somete después esos algoritmos al protocolo de evaluación offline y presenta los resultados obtenidos.

Conviene separar desde el principio dos planos que se confunden con facilidad. La literatura avala las *familias* de técnicas empleadas y los *principios* de ponderación, similitud, vecindad, hibridación, diversificación y medición; no convierte en constantes universales los valores numéricos concretos que este proyecto fija. Los pesos por familia de faceta, el parámetro β de la media F, el factor de contracción del rating, los pesos de estado de biblioteca, el umbral de evidencia negativa, el λ de la reordenación y los cortes K son decisiones explícitas de diseño para este corpus y este trabajo, tomadas y documentadas como tales, no resultados heredados de una publicación. Cada apartado indica qué parte pertenece a cada plano.

Los resultados publicados proceden de la ejecución evaluation-400-test-2026-09-12-v15, con el protocolo 15 y el *feature set*

fs-v12-curated-tags-idf. El código vigente evolucionó después al protocolo 16 y al *feature set* fs-v13-family-weighted-tags, que corrigió el reparto de peso entre familias de etiquetas descrito más abajo. Esa evolución permite describir con precisión la implementación actual, pero no recalcula ni reinterpreta las métricas ya publicadas de v15, y así se indica en cada cifra que proceda de una u otra versión.

5.5.1. Representación de una obra y del perfil de la persona usuaria

La arquitectura de recomendación basada en contenido que sigue el sistema (describir cada ítem con un conjunto de rasgos, construir un perfil de intereses a partir del historial de la persona y comparar ambos para ordenar candidatas) es la formulación clásica de la familia, descrita por Pazzani y Billsus [25]. Lo que este trabajo decide por su cuenta es qué rasgos concretos describen un videojuego, cómo se curan y con qué intensidad participa cada entrada de la biblioteca.

Una candidata para recomendar debe ser una obra gobernada del corpus, no contenido descargable, publicada antes de la fecha de corte, con valoración externa disponible y al menos cinco valoraciones agregadas; también se excluye cualquier obra que ya aparezca en la biblioteca de la persona. Estas exclusiones impiden recomendar una posesión ya conocida, lanzar contenido todavía no publicado o amplificar una nota sostenida por evidencia insuficiente.

Cada obra se representa mediante un vector disperso de familias de facetas: etiquetas de género y subgénero curadas, tema, característica, modo, franquicia, desarrollador y plataforma. Los géneros y subgéneros forman el núcleo semántico de la representación; tema, característica, modo, franquicia y desarrollador actúan como confirmaciones opcionales; la plataforma expresa compatibilidad material más que afinidad de gusto. Las *keywords*, perspectivas y modos crudos que ofrece la fuente de datos no se introducen directamente en el vector: tienen ruido, sinónimos y semánticas heterogéneas, de modo que solo entran tras una curación editorial que elimina duplicados y unifica niveles. Una faceta ausente en una obra se omite sin más; el sistema nunca imputa ni redistribuye su peso a otra familia, porque hacerlo premiaría la escasez de metadatos en lugar de ser neutral ante ella.

Dentro de cada familia, el peso de un valor concreto (por ejemplo, el género rpg o el tema cyberpunk) se calcula con una frecuencia documental inversa suavizada, de modo que un valor raro dentro de su propia familia pese más que uno común. El fundamento es la ponderación estadística de términos y la representación vectorial dispersa de Salton y Buckley [26]: los rasgos que aparecen en casi todos los documentos discriminan poco, y los infrecuentes discriminan mucho. Desde la revisión fs-v13, cada familia calcula su rareza sobre su propio universo de referencia, no sobre el corpus gobernado completo: si N_f es el número de obras gobernadas con algún valor de la familia f y df_t el número de esas obras que contienen el valor t ,

$$idf(t) = \ln\left(\frac{N_f + 1}{df_t + 1}\right) + 1, \quad (5.1)$$

con suavizado aditivo de 1 para mantener un valor finito incluso para un valor observado en una única obra. La versión anterior, fs-v12, no separaba las familias: género, subgénero, tema, modo y característica compartían un único presupuesto fusionado ($\text{tag} = 0,75$) con un solo cálculo de IDF entre las cinco. Eso permitía que un subgénero raro pesara más que el propio género por pura rareza estadística del conjunto fusionado. Una primera corrección, renormalizar las cinco familias juntas sin separarlas, se descartó porque terminaba premiando a las obras con menos metadatos en lugar de corregir el sesgo. La solución adoptada en fs-v13 fue separar cada familia en su propio cálculo de IDF, con su propio universo de referencia N_f y su propio peso ($\text{tag} = 0,60$, que fusiona género y subgénero; $\text{theme} = 0,20$; $\text{feature} = 0,10$; $\text{mode} = 0,05$; $\text{platform} = 0,05$), de modo que la rareza de un valor se mide siempre dentro de la población que realmente lo declara, no contra un denominador compartido con familias de cobertura muy distinta. La fórmula procede de la literatura; el cálculo de df sobre obras gobernadas, el suavizado y los pesos por familia son adaptaciones reproducibles a este corpus. Franquicia y desarrollador no usan IDF: si una obra declara k valores observados de esa familia, cada uno pesa $1/\sqrt{k}$, un reparto plano que evita premiar la rareza de un estudio o de una saga, señales de cobertura desigual en las que una coincidencia rara diría más del catálogo que del gusto de la persona.

Si T es el conjunto de valores que una obra declara en la familia f , el peso de la coordenada correspondiente a un valor t es

$$w(f:t) = W_f \cdot \frac{idf(t)}{\sqrt{\sum_{q \in T} idf(q)^2}}, \quad (5.2)$$

donde W_f es el peso fijo asignado a la familia f (Tabla 5.3) y la normalización L2 en el denominador, también procedente del modelo vectorial clásico [26], evita que una obra gane afinidad solo por declarar más valores dentro de la misma familia. El reparto concreto de W_f es, en cambio, una decisión de producto: prioriza la semántica de género sobre la compatibilidad de plataforma, que se mantiene como una restricción y no como una afinidad. Igualar ambos pesos se consideró y se descartó por ese mismo motivo.

Tabla 5.3: Peso fijo W_f de cada familia de faceta en el vector de contenido, fs-v13. Los valores son una decisión de diseño de SavePoint, no una constante de la literatura.

Familia	Peso W_f
Etiqueta de género/subgénero (tag)	0,60
Plataforma (platform)	0,05
Tema (theme)	0,20
Característica (feature)	0,10
Modo (mode)	0,05
Franquicia (franchise)	0,02
Desarrollador (developer)	0,015

El perfil de contenido de una persona usuaria se construye únicamente a partir de sus entradas de biblioteca terminadas o en curso con valoración personal de al menos siete medios puntos sobre diez; una entrada con valoración inferior a ese umbral no se añade al perfil positivo, sino que alimenta un perfil de evidencia negativa aparte. Cada entrada i aporta un peso de actividad $entry_weight_i = status_weight_i + r_i^2$, donde $status_weight$ vale 3 para una obra terminada, 2 para una obra en curso, 1 para pendiente y 0 para abandonada, y r_i es la valoración personal normalizada a $[0, 1]$. Elevar la valoración al cuadrado hace que una nota alta cuente como evidencia bastante más intensa que una simplemente positiva. Esta forma de modular la contribución de cada ítem del historial es la aplicación directa del principio de perfil ponderado por interés de la familia basada en contenido [25]; los valores 3, 2, 1 y 0 y el exponente cuadrático son decisión local. El perfil es la media ponderada de los vectores normalizados de las entradas elegibles, y no se vuelve a normalizar globalmente después; conserva así la intensidad relativa acumulada de la biblioteca. Cuando una etiqueta se repite en al menos tres entradas de baja valoración, se activa como evidencia negativa. Ese umbral de tres es deliberado: una penalización sin umbral convertiría una única experiencia mal valorada en un rechazo estable, que es precisamente el error que se quería evitar. Con menos de tres entradas positivas elegibles, o sin ningún vector de features disponible, el sistema entra en un modo explícito de historial insuficiente: no inventa un perfil ni recurre silenciosamente a la biblioteca de otra persona; esa limitación queda declarada así en la respuesta.

5.5.2. Similitud de contenido y señales escalares de la candidata

La similitud entre el perfil de una persona y una obra candidata no aplica el coseno ciegamente sobre todo el vector. Para cada familia se calculan por separado la cobertura del perfil y la precisión de la candidata: si P_f y C_f son los valores de perfil y candidata en la familia f , y $O_f = P_f \cap C_f$ su solapamiento,

$$coverage_f = \frac{\sum_{t \in O_f} P_f[t]}{\sum_{t \in P_f} P_f[t]}, \quad precision_f = \frac{|O_f|}{|C_f|},$$

y ambas cantidades se combinan con una media F_β con $\beta = 0,5$,

$$F_{0,5} = \frac{(1 + 0,5^2) \cdot coverage \cdot precision}{0,5^2 \cdot precision + coverage}, \quad (5.3)$$

La media F_β como forma canónica de equilibrar precisión y cobertura con un único parámetro procede de van Rijsbergen [27]; el valor $\beta = 0,5$ es la decisión local, y da más peso a la precisión de la candidata que a la cobertura del perfil, de modo que una obra que declara muchos valores de una familia no gana automáticamente por enumerar más. Se consideraron dos alternativas y se descartaron por motivos concretos: una media aritmética simple favorece a las candidatas con más metadatos declarados, y el coseno puro sobre el vector

completo, aunque más habitual, resulta menos separable a la hora de explicar por qué se recomienda una obra y más vulnerable a las candidatas con muchas facetas.

Desde fs-v13, el núcleo renormalizado de la similitud se limita a las dos familias con cobertura casi universal, etiqueta y plataforma, ponderadas exactamente con los pesos $W_{tag} = 0,60$ y $W_{platform} = 0,05$ de la Tabla 5.3:

$$core = \frac{\sum_{f \in \{tag, platform\}} W_f \cdot F_{0,5,f}}{\sum_{f \in \{tag, platform\}} W_f \text{ activos}}.$$

Las cinco familias restantes (tema, característica, modo, franquicia y desarrollador) suman un bono de confirmación acotado, fuera de ese núcleo, que nunca resta ni se redistribuye cuando una familia falta en cualquiera de los dos lados:

$$\begin{aligned} bonus = & 0,20 aff_{tema} + 0,10 aff_{caracteristica} + 0,05 aff_{modo} \\ & + 0,02 aff_{franquicia} + 0,015 aff_{desarrollador}, \end{aligned} \quad (5.4)$$

con $aff_f = \min(1, \sum_{t \in O_f} P_f[t] / \max_{t \in P_f} P_f[t])$ y la similitud final $similarity = \min(1, core + bonus)$. Esta asimetría entre núcleo y bono es deliberada: un tema, una saga o un estudio confirman un interés ya observado en el género o la plataforma, pero no deben sustituir esa similitud semántica ni inflarla artificialmente cuando falta información secundaria. Situar franquicia o desarrollador en el núcleo se descartó por su cobertura desigual y por el riesgo de recomendar por coincidencia superficial de editor más que por afinidad real. El coseno completo sobre el vector no desaparece: se reserva para medir la redundancia entre recomendaciones y la diversidad intra-lista de las variantes con reordenación, donde su interpretación geométrica directa sí es exactamente la propiedad necesaria.

La calidad externa de una candidata no usa su valoración agregada en bruto, sino que se estabiliza con contracción (*shrinkage*) bayesiana hacia la media del corpus, para que una nota extrema sostenida por pocas observaciones no domine el resultado. El fundamento es el principio de Empirical Bayes: las observaciones escasas se contraen hacia un prior común para reducir la varianza del estimador [28]. Con n valoraciones observadas, prior del corpus μ (la media de valoraciones ponderada por su propio volumen de votos) y un parámetro de contracción $m = 25$,

$$rating_{bayes} = \frac{n \cdot rating + m \mu}{n + m}, \quad rating_{final} = \left(\frac{rating_{bayes}}{100} \right)^2 \cdot \frac{n}{n + m}.$$

El valor $m = 25$, el exponente cuadrático sobre la nota normalizada y el factor de confianza $n/(n + m)$ son, de nuevo, decisiones locales: el cuadrado separa mejor a las candidatas de calidad alta y el factor de confianza penaliza de forma

explícita el volumen de evidencia, no solo la nota media. Usar la valoración en bruto se descartó por el sesgo evidente de las notas extremas con poca evidencia, y volver a multiplicar por el volumen de votos también, porque ese volumen ya participa una vez dentro de la propia contracción. Cuando una candidata no tiene valoración externa propia observada, el sistema recurre a la mediana de valoración de sus etiquetas curadas y marca el resultado como una aproximación, sin presentarlo como una observación real.

La popularidad externa (*PopScore*) tampoco usa el valor bruto de la fuente de datos: su escala es larga y arrastra un sesgo de popularidad conocido, así que cada una de sus cuatro primitivas se transforma con $\log(1 + x)$ y después se convierte en un percentil de rango dentro del snapshot congelado, combinándose como $PopScore = 0,40 \text{ Visitas} + 0,25 \text{ Jugando} + 0,25 \text{ Jugado} + 0,10 \text{ Quiere jugar}$. Si falta cualquier primitiva, no existe composición observada y las variantes que la consumen aplican un suelo explícito de cero, marcado como tal, sin redistribuir el peso que le correspondía. La recencia, por último, solo es estimable para una obra con fecha de lanzamiento no futura: con *year_gap* el número de años naturales transcurridos desde su publicación hasta la fecha de corte, $recency = 0,35^{year_gap}$, de modo que una obra del año del corte vale 1,0, una del año anterior 0,35 y así sucesivamente. Se eligió una base geométrica sobre años naturales en lugar de una semivida diaria porque esta última es menos interpretable y depende del día exacto del corte, lo que la haría frágil ante una repetición del experimento en otra fecha.

5.5.3. Las tres familias y sus dieciséis variantes

Con la afinidad de contenido *C*, la calidad *R*, la popularidad *P*, la evidencia negativa *N* y la recencia *X* ya definidas, la Tabla 5.4 recoge la fórmula exacta de las diez variantes basadas en contenido. Todas comparten el mismo conjunto de candidatas, el mismo vector de features y el mismo perfil de usuario; lo único que cambia entre ellas es cómo combinan sus señales, precisamente para que la comparación aísle esa decisión de diseño y no otra.

Tabla 5.4: Fórmula de combinación de las diez variantes basadas en contenido.

Algoritmo	Fórmula
content-cbf-weighted-v1	$S = 0,70 C + 0,30 R$
content-cbf-multiplicative-v1	$S = C \cdot R$
content-cbf-twostage-v1	$b = \min(4, \lfloor 5C \rfloor); S = b + R/6$
content-cbf-neg-v1	$S = \max(0, 0,70C + 0,30R - N)$
content-cbf-weighted-pop-v1	$S = 0,55C + 0,25R + 0,20P$
content-cbf-multiplicative-pop-v1	$S = C \cdot R \cdot (0,80 + 0,40P)$
content-cbf-twostage-pop-v1	$b = \min(4, \lfloor 5C \rfloor); S = b + (0,80R + 0,20P)/6$
content-cbf-neg-pop-v1	$S = \max(0, 0,55C + 0,25R + 0,20P - N)$
recency-v1	$S = 0,20C + 0,20R + 0,20P + 0,40X$
content-cbf-mmrv1 / -pop-v1	MMR sobre Weighted / Weighted-Pop

La existencia de estas diez variantes no responde a un afán de acumular algoritmos, sino al diseño experimental: cada una aísla una única decisión de combinación manteniendo constantes las candidatas, las features y los snapshots, de modo que una diferencia de resultado se pueda atribuir a esa decisión concreta. `content-cbf-weighted-v1` actúa como referencia del grupo porque sus pesos son explícitos y su comportamiento es fácil de explicar: el contenido domina la puntuación y la calidad ordena dentro de un mismo nivel de afinidad. La variante multiplicativa exige afinidad y calidad simultáneamente, sin que una compense a la otra. La de dos etapas usa la afinidad para asignar una banda discreta y solo desempata dentro de ella con la calidad, de modo que una nota alta nunca rescata una afinidad baja. La negativa resta la evidencia de rechazo acumulada sobre las mismas etiquetas. Las cuatro variantes con sufijo `-pop` repiten exactamente esas combinaciones incorporando además un veinte por ciento de PopScore, con el resto de pesos reescalados para que la suma se mantenga acotada; en la multiplicativa, un PopScore nulo produce un factor 0,80 y uno máximo un factor 1,20, un ajuste acotado y nunca una sustitución de la afinidad de contenido. `recency-v1` reparte su peso entre las cuatro señales con un cuarenta por ciento para la novedad, lo que la convierte en una variante de descubrimiento sin abandonar del todo la personalización.

Fuera de la familia de contenido, `cf-user-knn-v1` implementa el filtrado colaborativo por vecindad de usuarios en la forma que introdujeron Resnick y otros en GroupLens [29] y que sistematizaron Herlocker y otros [13]: similitud entre personas calculada sobre las obras que ambas han valorado, valoraciones centradas por la media de cada persona y predicción por agregación ponderada de las desviaciones de los vecinos. Las decisiones locales son el mínimo de dos obras co-valoradas para considerar fiable una vecindad y el máximo de veinte vecinos con similitud positiva. Es explicable por los vecinos y las obras que comparten, pero sufre arranque en frío: con historial escaso, o sin vecindad suficiente, no puede inferir una preferencia colaborativa fiable. Se descartó implementar en su lugar un colaborativo por vecindad de ítems porque exige construir una matriz ítem-ítem y descansa sobre otra hipótesis de generalización, mientras que la vecindad de usuarios resulta más legible con el rating explícito disponible en este corpus.

El híbrido responde al argumento de Burke [12]: combinar fuentes complementarias permite aprovechar las ventajas de cada una y compensar sus debilidades. Su combinación es $H(i) = 0,60 \text{Weighted}(i) + 0,40 \text{CF}(i)$; si el componente colaborativo no dispone de historial suficiente, el híbrido conserva la relevancia de contenido y declara el *fallback* en lugar de penalizar artificialmente a una persona nueva. El reparto 0,60/0,40 es en sí mismo una decisión local sujeta a evaluación, no una regla tomada de la literatura.

Las dos variantes con reordenación por diversidad aplican *maximal marginal relevance* tal como lo formularon Carbonell y Goldstein [30]: recorren un conjunto de tamaño $\max(100, 5K)$ y en cada posición eligen la candidata que maximiza $\lambda \text{Rel}(i) - (1 - \lambda) \max_{j \in S} \text{cosine}(i, j)$, con $\text{Rel}(i)$ la relevancia ya calculada y S la lista parcial ya elegida. El valor $\lambda = 0,80$ y el tamaño del conjunto son decisiones locales. La motivación de fondo es la advertencia de McNee, Riedl y Konstan [31] y

el marco de medición de Vargas y Castells [32]: la exactitud no agota la utilidad de una recomendación, y diversidad, novedad y cobertura deben medirse aparte en lugar de quedar escondidas dentro de la puntuación. Por eso la diversificación se implementó como una capa de reordenación explícita y no como un término más dentro de los pesos de afinidad, ni como una optimización multiobjetivo del propio *score*: separarlas permite estudiar el compromiso entre relevancia y redundancia en lugar de ocultarlo.

5.5.4. Variantes publicadas en la aplicación

De las dieciséis variantes, la aplicación web publica solo tres: `content-cbf-weighted-v1`, `content-cbf-mmr-pop-v1` y `recency-v1`. Cada una responde a un criterio distinto. La primera es la referencia de la familia de contenido: el contenido domina la puntuación y la calidad externa ordena dentro de un mismo nivel de afinidad. La segunda añade popularidad y una reordenación por diversidad, para que la lista no repita variaciones del mismo juego. La tercera favorece los títulos recientes y actúa como variante de descubrimiento. La selección es una decisión de diseño de producto: ofrecer a la persona usuaria dieciséis listas con resultados muy parecidos entre sí no aporta valor y empeora la experiencia, y mantener un *worker* activo por cada variante supone un coste de recursos que no se justifica. Las demás variantes se conservan en el laboratorio de evaluación, donde cumplen su función, que es compararlas bajo un mismo protocolo, y no afectan a esta selección: el Capítulo 7 evalúa las dieciséis.

5.5.5. Alternativas descartadas y su justificación

Las familias implementadas son interpretables y adecuadas para una población controlada, pero no agotan el espacio de recomendación. La Tabla 5.5 recoge las alternativas que se consideraron de forma explícita, con su respaldo en la literatura cuando lo tienen, y el motivo por el que no se adoptaron en esta versión.

Tabla 5.5: Alternativas consideradas y motivo de exclusión.

Alternativa	Motivo de exclusión
Factorización matricial (ALS, BPR) [33]	Añade entrenamiento, factores latentes e hiperparámetros; dificulta atribuir un resultado a una señal concreta sobre población sintética
Redes neuronales, <i>embeddings</i> o modelos de lenguaje	Coste, opacidad y requisitos de datos no justificados por el objetivo del trabajo
Modelos de grafos o secuenciales	El historial disponible no sostiene una hipótesis temporal que justifique esa complejidad
Colaborativo por vecindad de ítems	Exige matriz ítem-ítem y otra hipótesis de generalización; user-KNN es más legible con rating explícito
Coseno puro como similitud principal	Menos separable en las explicaciones y más vulnerable a candidatas con muchas facetas
Media aritmética en lugar de $F_{0,5}$	Favorece a las candidatas que declaran más metadatos
Rating externo en bruto	Sesgo de las notas extremas con poca evidencia; la contracción bayesiana lo corrige
PopScore en bruto	Escala larga y sesgo de popularidad; se normaliza por percentil dentro del snapshot
Optimización multiobjetivo del <i>score</i>	Escondería la diversidad dentro de los pesos de afinidad en lugar de permitir estudiarla
Métricas de error sobre la nota predicha	Miden predicción de valoración, no calidad del orden de la lista [15]

Estas exclusiones son decisiones de alcance y de validez, no afirmaciones de que los métodos descartados sean universalmente peores. La factorización matricial, en particular, es una alternativa reconocida y competitiva en recomendación colaborativa [33]; no se incorpora porque el objetivo de este trabajo exige comparar señales legibles sobre una población controlada, y un modelo de factores latentes introduciría entrenamiento y grados de libertad que harían mucho más difícil atribuir una diferencia de resultado a una señal concreta. Cualquiera de ellas podría evaluarse en una extensión del trabajo, pero exigiría una variante versionada, nuevos controles de datos y una comparación bajo el mismo protocolo.

5.6. Diseño del laboratorio de evaluación

El laboratorio se diseñó como una tubería fuera de línea, separada de las peticiones de usuario. Su entrada no es el valor mutable de `GameWork.total_rating`, sino una pareja de versión de corpus y snapshot de valoraciones. A partir de ella, el runner resuelve la partición de usuarios, construye el manifiesto de candidatos de cada usuario y ejecuta las variantes sobre la misma entrada. El artefacto resultante

debe conservar la versión del código, la huella del protocolo, las semillas, la huella del manifiesto y las métricas por usuario y por k . La Figura 5.4 resume esa tubería.




Figura 5.4: Tubería de la evaluación offline, de los datos congelados al artefacto versionado.

La aplicación `evaluation` separa cuatro responsabilidades. El cargador del protocolo valida las claves, el tamaño de la rejilla y el consumo único del test. El módulo de particiones selecciona la obra relevante retenida y comprueba que `train`, `validation` y `test` sean conjuntos disjuntos y completos. El módulo de métricas calcula $P@K$, $R@K$, $nDCG@K$ y $MAP@K$ con fórmulas escritas y probadas en el proyecto. Por último, el runner orquesta los algoritmos y escribe un artefacto JSON con sus huellas y resultados.

Todas las variantes comparten el conjunto de candidatos, la semántica de exclusión y el DTO versionado; el modelo de contenido que usan es el descrito en la Sección 5.5. Las explicaciones no generan texto libre: devuelven una tabla determinista de contribuciones por faceta, el valor del término de rating y si se usó el fallback. El parámetro `algorithm_id` solo puede seleccionar identificadores de una allowlist, nunca una función o importación dinámica.

Este capítulo ha descrito cómo se diseñaron la plataforma, los algoritmos de recomendación y el laboratorio que los compara. El capítulo siguiente describe su implementación.

6. Implementación y pruebas

Este capítulo describe cómo se ha construido el sistema. Empieza por el entorno reproducible y las versiones fijadas, sigue con la adquisición y el gobierno de los datos, con el backend y con el frontend; termina con las pruebas, la verificación y el despliegue. Incluye extractos de código representativos, todos referenciados en el texto.

6.1. Entorno reproducible y dependencias

El entorno de desarrollo y de pruebas se orquesta con Docker Compose, con tres servicios de aplicación (base de datos, backend y frontend), además de los *workers* de las variantes de recomendación que publica la web (Sección 5.5.4). Las dependencias se fijan a versión exacta, con `uv` para Python y `pnpm` para Node. Sus ficheros de bloqueo se congelan en las construcciones. Las imágenes base se fijan por resumen criptográfico. La Tabla 6.1 recoge las versiones principales.

Componente	Versión	Papel
Python	3.13.7	Lenguaje del backend y de los guiones de datos.
Django	5.2.17 LTS	Dominio, autenticación, ORM, sesiones y migraciones.
Django REST Framework	3.18.0	Serialización, permisos y API.
PostgreSQL	18.6	Base de datos de aplicación y de pruebas de integración.
psycopg	3.3.5	Controlador de PostgreSQL.
Node.js	24.13.0	Ejecución del frontend.
Next.js	16.3.4	Renderizado en el servidor, rutas y metadatos.
React	19.2.7	Modelo de componentes.
TypeScript	6.0.3	Tipado estricto del frontend.
Tailwind CSS	4.3.3	Tokens de diseño y maquetación adaptable.

Tabla 6.1: Versiones principales del entorno reproducible.

Toda dependencia directa nueva o cambio de versión pasa por un gate: aprobación humana explícita, verificación de la ficha oficial del repositorio de paquetes, fijación a versión exacta con su árbol transitivo en el fichero de bloqueo, una fila en `docs/verification/dependency-legitimacy.md`, una fila en el `gate check-dependencies.ps1` y una entrada en el registro de agentes. En el sistema solo se añadieron dos dependencias directas. La primera es `requests` en la versión

2.34.2, para el importador de IGDB. La segunda es gunicorn en la versión 23.0.0, como servidor de producción de la API tras una revisión de código. Ambas se verificaron contra la ficha oficial del índice de paquetes de Python, con su licencia, su versión mínima de intérprete y su fecha de publicación reales.

6.2. Adquisición y gobierno de datos

Esta sección describe de dónde salen los datos del catálogo, bajo qué licencia se usan y qué evidencia de procedencia se conserva. El sistema integra dos fuentes de datos de catálogo. La primera es un corpus curado de ciento cincuenta juegos procedente de Wikidata, que actúa como la referencia citable y estable. La segunda es el catálogo a escala real procedente de IGDB, con más de trescientas mil obras. Las dos conviven en la base de datos, indexadas por su fuente, pero la evaluación solo consume la vista gobernada y versionada. La Figura 6.1 recoge el recorrido completo de los datos, de las fuentes al laboratorio.




Figura 6.1: Flujo de los datos del catálogo, desde las fuentes hasta el laboratorio de evaluación.

6.2.1. Fuentes: corpus de Wikidata y catálogo de IGDB

El corpus curado son ciento cincuenta juegos de datos estructurados de Wikidata, publicados bajo la dedicación al dominio público *Creative Commons Zero* (CC0) [4]. La adquisición se hace fuera de línea con un guion que lanza una consulta filtrada por clase contra el punto de acceso SPARQL de Wikidata, resuelve las subconsultas de plataforma de forma dinámica y valida la estructura y la cobertura por época del resultado. El guion escribe el fichero `data/raw/wikidata-games.json` con su huella SHA-256, más los manifiestos de catálogo y de recursos. El registro de decisión ADR-003 y el documento `docs/verification/catalogue-freeze.md` conservan la consulta, la fecha de corte

en tiempo universal coordinado, la huella y la aprobación humana explícita del corpus.

Los archivos multimedia se tratan por separado, porque no comparten la licencia de los datos estructurados. De diecinueve archivos de Wikimedia Commons revisados uno a uno, diecisiete se admitieron con crédito completo de autor, licencia y fuente. Los dos restantes se sustituyeron por un marcador de reserva de primera parte [5]. El identificador de Wikidata se conserva solo como procedencia en SourceRecord, nunca como clave primaria, de modo que la identidad del producto no queda acoplada a la fuente.

El catálogo a la escala de un producto real se construye con la API de versión 4 de IGDB [6]. El requisito DATA-04 exige elegir la fuente mediante una comparación documentada de cobertura, plataformas, licencia, atribución, cuotas, estabilidad y coste. La Tabla 6.2 resume esa comparación, que se apoya en un sondeo autenticado en vivo de la API ejecutado el 5 de septiembre de 2026 y en fuentes secundarias para las otras dos opciones.

Eje	IGDB (elegida)	RAWG	Wikidata escalado
Cobertura	374.555 entradas totales, 312.418 juegos principales, medidos en vivo	Entre 350.000 y 500.000 declarados, fuente secundaria	Escasa y desigual para juegos
Plataformas	Entidad de primera clase, 220 filas	Metadatos de primera clase, fuente secundaria	Presentes pero inconsistentes
Licencia	<i>Twitch Developer Services Agreement</i> , gratuita para uso comercial y no comercial	Nivel gratuito solo no comercial	CC0, la más limpia
Atribución	Estática y visible a IGDB.com	Obligatoria con enlace de vuelta en cada página	No requerida para datos CC0
Cuotas	Sin cuota mensual; 4 peticiones por segundo	20.000 peticiones al mes en el nivel gratuito	Sin cuota, sujeta a límites del punto de acceso
Estabilidad	API v4 estable desde 2020, respaldada por Twitch	Operador independiente, mayor riesgo	Muy estable como institución, datos de juegos volátiles
Coste	Cero	Cero dentro de la cuota	Cero

Tabla 6.2: Comparación DATA-04 de fuentes para el catálogo a escala real.

De la comparación se desprende la elección de IGDB, la única opción que combina cobertura real, modelado de género y plataforma de primera clase, ausencia de cuota mensual y coste cero, a cambio de una obligación de atribución continua. La frontera de categoría es `game_type = 0`, es decir, solo juegos

principales; el contenido descargable, las expansiones, los paquetes y los ports quedan excluidos del catálogo primario. Las portadas se sirven por enlace directo al servidor de imágenes de IGDB, no se replican, con el marcador de reserva de primera parte como alternativa cuando una portada falta o falla. La regla de caché y redistribución se apoya en el texto de la propia documentación de la API, que prefiere que el integrador almacene y sirva los datos a sus usuarios finales, texto que se registra literalmente en el repositorio como la autorización escrita que contempla el acuerdo general [7]. El corpus de Wikidata y su regla de no consultar proveedores en tiempo de petición se conservan sin cambios; la importación de IGDB es aditiva y se ejecuta solo desde un comando de gestión fuera de línea.

6.2.2. Congelación y gobierno del corpus

Una revisión humana fila a fila no es posible con cientos de miles de obras, ni es el modelo legal correcto para las portadas de IGDB. El documento docs/verification/igdb-catalogue-freeze.md congela en su lugar tres artefactos: una huella de contenido, que es un SHA-256 sobre los pares de identificador de origen y huella normalizada de cada registro de procedencia de IGDB, ordenados por identificador numérico; una cobertura agregada, con el total de obras primarias, la distribución de géneros, las plataformas más frecuentes, el histograma de año de lanzamiento y el reparto entre portada presente y de reserva; y un manifiesto de revisión muestreada determinista de trescientos registros, tomando uno de cada mil cuarenta y uno por orden de identificador, con datos suficientes para una comprobación humana puntual. La Tabla 6.3 recoge los valores medidos en la carga de la base de datos de desarrollo persistente y actualizados durante la Fase 2, el 7 de septiembre de 2026.

Campo	Valor
Obras primarias de IGDB importadas	312.560
Corpus de Wikidata conservado	150
Total de obras en el catálogo	312.710
Géneros	23
Plataformas (Wikidata e IGDB reconciliadas)	288
Portadas presentes / de reserva	268.679 / 43.804
Fecha de primer lanzamiento poblada	aproximadamente el 75 % de las filas
Obras con rating de usuarios de IGDB	27.014 (13,9330 % del corpus gobernado)
Cobertura de total_rating	15,8197 % del corpus gobernado
Huella de contenido (SHA-256)	ff3d67525c92. . .

Tabla 6.3: Evidencia agregada de congelación de la importación de IGDB.

La importación se probó además sobre una base de datos desechable, donde sobrevivió a una interrupción abrupta tras dos lotes confirmados y reanudó hasta

completar sin duplicados ni huecos. Una segunda pasada completa sobre la base ya poblada convergió de forma idempotente, con la única diferencia de dos juegos primarios que IGDB añadió en vivo entre las dos pasadas. El snapshot reutilizable de la base cargada, de noventa y tres megabytes, no se versiona en el repositorio por decisión de ADR-006; se conserva fuera de él como vía de restauración rápida.

La Fase 2 añadió una frontera de evaluación sobre este catálogo. El comando `govern_corpus` aplica las reglas D-03 de forma reversible: conserva las obras fuente, pero marca como gobernadas las que son obras principales, tienen fecha de lanzamiento, al menos un género y al menos una plataforma de la allowlist de 39 plataformas. El rating no es un criterio de exclusión. La ejecución documentada dejó 193.885 obras gobernadas y una versión de corpus 2026.09.1; el checksum, el diccionario, el informe de calidad y la muestra determinista se conservan en `docs/verification/corpus-governance-freeze.md`.

6.2.3. Ratings externos y aislamiento de la evaluación

Durante la reimportación de IGDB se añadieron los campos `rating`, `rating_count` y `total_rating_count`, además del resumen y los alias alternativos. El campo `rating` representa la valoración de usuarios de IGDB en una escala de 0 a 100; `total_rating` representa la valoración agregada disponible en IGDB. Son señales distintas y por eso se almacenan con nombres distintos. En el corte de 2026.09.1, la cobertura de ambos campos sobre las obras gobernadas es la que recoge la Tabla 6.3.

El comando `snapshot_corpus_ratings` copia las valoraciones externas a `CorpusRatingSnapshot` con una operación `insert-only` asociada a una `corpus_version`. Una reimportación puede actualizar los campos vivos que usa la interfaz y producir una versión posterior, pero no modifica el snapshot de una versión ya utilizada por el laboratorio. Esta separación es la condición que permite repetir una comparación y explicar qué datos recibió.

Como fuente secundaria se probó RAWG en una ejecución acotada a 10.000 obras seleccionadas por `rating_count` de IGDB. La reconciliación fue determinista: primero se intentó el slug exacto y después el título normalizado junto con el año de lanzamiento. No se aplicó fuzzy matching; las filas no emparejadas se descartaron y se contabilizaron. El resultado fue de 8.575 emparejamientos y 1.425 descartes, con 8.575 snapshots RAWG insertados. La cobertura nueva fue cero porque las obras seleccionadas ya tenían rating de IGDB. RAWG se documenta, por tanto, como contraste de procedencia, no como una fuente que haya ampliado la cobertura del corpus.

La valoración mostrada en la ficha es una decisión de producto diferente. Puede mezclar, con pesos limitados por la cantidad de observaciones, el rating externo y las valoraciones locales de las personas usuarias. El laboratorio no lee esa mezcla derivada ni el valor mutable de `GameWork`: utiliza los snapshots de la versión fijada. Esta distinción evita que una nueva valoración de una cuenta o una reimportación cambie retroactivamente un resultado académico.

6.3. Backend

6.3.1. Comandos de gestión y del laboratorio

Toda tarea de datos es un comando de gestión de Django, ejecutable fuera de la petición HTTP e idempotente. El importador de Wikidata, `import_catalogue`, carga el corpus curado de Wikidata. El importador de IGDB, `import_igdb_catalogue`, recorre la API por lotes con un cursor de identificador reanudable: cada lote se confirma dentro de una transacción que también escribe el cursor. Un disparador de base de datos impide que ese cursor retroceda, de modo que una ejecución interrumpida siempre reanuda hacia delante desde el progreso real. La cadena de arranque del despliegue encadena la migración y la importación del catálogo, como describe la Sección 6.6.

La gobernanza y los ratings externos de la Sección 6.2 se ejecutan con `govern_corpus`, `snapshot_corpus_ratings` y `enrich_rawg_ratings`, que trabaja por lotes con *backoff* ante respuestas transitorias. `backfill_game_aliases` reconstruye los alias normalizados para que la búsqueda sea útil sobre el catálogo real.

El protocolo se carga desde `docs/methodology/protocol.json`. Los módulos de la aplicación `evaluation` que describe la Sección 5.6 se implementan con funciones deliberadamente pequeñas y explícitas. `evaluation/protocol.py` rechaza una rejilla con más de 24 configuraciones y distingue un protocolo todavía no consumido de un test ya ejecutado. `evaluation/metrics.py` no delega la definición de $P@K$, $R@K$, $nDCG@K$ o $MAP@K$ en una librería externa. `evaluation/splits.py` deriva la semilla del protocolo y del usuario, para que el orden de las filas en la base de datos no altere la obra retenida.

6.3.2. Vistas, búsqueda y filtrado

La configuración de DRF fija la autenticación por sesión como única clase de autenticación, de modo que no queda habilitada ninguna vía de autenticación básica sin límite de ritmo. Los límites de ritmo de las vistas anónimas de mayor coste son: cinco registros por hora, diez intentos de acceso por minuto, treinta consultas de perfil por minuto y ciento veinte búsquedas de catálogo por minuto. El número de proxies de confianza se lee de una variable de entorno, con valor cero en local, para que el límite de ritmo por dirección se agrupe correctamente detrás del proxy del mismo origen.

La búsqueda del catálogo es tolerante: primero coincidencia exacta, después por prefijo y por último por similitud de trigramas para erratas pequeñas, siempre sobre el índice de alias normalizados y sin ninguna llamada externa. Sobre ese resultado se cruzan los filtros de plataforma, género, año y nota mínima. Una lista fija de claves de ordenación se traduce a un `order_by` determinista con desempate por identificador canónico. El texto de ordenación que envía el cliente nunca se interpola: una clave desconocida produce un error acotado antes de tocar el ORM. El Extracto de código 6.1 muestra esa lista de ordenaciones permitidas.

```

1 # Cada clave resuelve a una tupla de argumentos de order_by que SIEMPRE
2 # termina en canonical_slug, de modo que todo orden es total y estable
3 # entre llamadas. Nada derivado de la entrada del cliente llega a este
4 # diccionario: una clave no reconocida lanza un error antes de construir
5 # la consulta.
6 SORT_ORDERS = {
7     "title_asc": ("original_title", "canonical_slug"),
8     "title_desc": ("-original_title", "canonical_slug"),
9     "release_newest": (F("first_release_date").desc(nulls_last=True), "
canonical_slug"),
10    "release_oldest": (F("first_release_date").asc(nulls_last=True), "
canonical_slug"),
11    "rating_desc": (F("total_rating").desc(nulls_last=True), "
canonical_slug"),
12 }

```

Extracto de código 6.1: Lista fija de ordenaciones del catálogo, con desempate por identificador canónico (apps/api/catalogue/search.py).

6.3.3. Recomendadores en la aplicación

La aplicación publica tres variantes del laboratorio (Sección 5.5.4), cada una servida por su *worker*. Además, el baseline rank_random_v1 es el suelo de comparación. Selecciona con `random.Random(seed)` sobre los candidatos gobernados que no aparecen en la biblioteca de la persona usuaria. Ordenar previamente los identificadores y guardar una huella de la semilla, los candidatos y el resultado hace que la misma entrada produzca exactamente el mismo ranking.

El modelo de contenido que usan los algoritmos, descrito en la Sección 5.5, se apoya en `WorkFeatureVector`, una caché versionada y no un modelo entrenado, que `rebuild_feature_vectors` rellena de forma idempotente. El perfil de usuario reutiliza la tabla de pesos del heurístico que se describe a continuación, y el rating se mantiene fuera del vector para poder estudiarlo como una señal independiente.

La página de recomendaciones se apoya en el heurístico `tag-taste-v1` (identificador histórico `genre-taste-v1`, renombrado tras generalizarse a etiquetas curadas más allá del género), descrito en el registro ADR-007. Es una agregación en tiempo de petición, sin estado, acotada a la persona autenticada. Cada entrada de la biblioteca de esa persona aporta un peso de actividad a cada género de su obra, según la fórmula del Extracto de código 6.2, que un refactor posterior extrajo al módulo `apps/api/recommendations/_weights.py`. Así, el propio heurístico y el perfil de contenido (Sección 5.5) usan la misma definición de peso en lugar de copiarla. La contribución de la valoración no es lineal, como explica la Sección 5.5. Las obras del catálogo no vistas y sin ser contenido descargable se ordenan por el peso sumado de los géneros que comparten con ese vector de gusto, con desempate por identificador canónico. Cada respuesta lleva una huella SHA-256 del vector de gusto y del resultado ordenado, de modo que dos llamadas con la misma entrada producen la misma huella. Sin actividad con género, la respuesta es una forma

```

1 # Pesos compartidos por el heurístico y el perfil de contenido.
2 # Una obra abandonada no aporta evidencia positiva.
3 _STATUS_WEIGHTS = {
4     "completed": 3.0,
5     "playing": 2.0,
6     "pending": 1.0,
7     "abandoned": 0.0,
8 }
9
10 # La intensidad crece de forma no lineal con la valoración.
11 _RATING_DIVISOR = 10
12 RATING_INTENSITY_POWER = 2.0
13
14 def _rating_intensity(rating_half_steps):
15     if rating_half_steps is None:
16         return 0.0
17     normalised = max(
18         0.0,
19         min(1.0, rating_half_steps / _RATING_DIVISOR),
20     )
21     return normalised ** RATING_INTENSITY_POWER
22
23 def _entry_weight(status, rating_half_steps):
24     status_weight = _STATUS_WEIGHTS.get(status or "", 0.0)
25     return status_weight + _rating_intensity(rating_half_steps)

```

Extracto de código 6.2: Cálculo del peso de actividad de una entrada de biblioteca.

explícita de historial insuficiente que nunca cae al baseline de popularidad.

La frontera de este heurístico es explícita. Es un conteo de frecuencia sobre una tabla, sin paso de entrenamiento, sin vectores latentes y sin almacén de características persistido. No reclama calidad predictiva y su cadena de limitación, incluida en cada respuesta, dice con palabras que no participa en la comparación sistemática de recomendadores que presenta el Capítulo 7. Su papel es doble: hacer que el producto se lea como un sitio de catalogación real y dejar un contrato de página y de punto de acceso ya cableado, el mismo que las familias de recomendación comparadas en esta memoria terminaron ocupando.

6.4. Frontend

El frontend usa el enrutador de aplicación de Next.js, con un segmento de idioma en la raíz de la ruta. Las rutas del sistema son la página de inicio, el catálogo, el detalle de un juego, la colección, las amistades, el perfil de un amigo, las fuentes, el acceso, el registro y las recomendaciones. Los componentes reutilizables son los que fija el contrato de diseño de la Sección 5.4, además del armazón de la aplicación con su barra de navegación. Las páginas de solo lectura

se renderizan en el servidor; los controles de biblioteca son componentes de cliente que llaman a la API del mismo origen. Las Figuras 6.2 y 6.3 muestran el catálogo con sus filtros y la colección de la persona usuaria.




Figura 6.2: Catálogo con tema oscuro, búsqueda y filtros por plataforma, género, año y valoración. Fuente: captura del proyecto.

La interfaz está disponible en español y en inglés. Los textos viven en diccionarios por idioma. Una prueba de paridad falla si una clave existe en un idioma pero no en el otro, de modo que ninguna cadena queda sin traducir.

La reescritura del lado del servidor que describe la Sección 5.3 reenvía las rutas bajo `/api/` y la ruta de chequeo de salud hacia el backend, con el destino tomado de una variable de entorno visible únicamente en el servidor. El Extracto de código 6.3 la muestra.

Las Figuras 6.4 y 6.5 muestran las dos vistas de recomendaciones disponibles en el proyecto, junto a la portada ya presentada en la Figura 5.2; son capturas de interfaz, no evidencia de calidad de ranking ni de resultados experimentales.




Figura 6.3: Colección de la persona usuaria con tema oscuro, con el estado y la valoración de cada juego. Fuente: captura del proyecto.

```

1 // El navegador solo habla con este origen de Next.js: las cookies de
2 // sesion y CSRF que fija Django siguen siendo del mismo origen y no hace
3 // falta ninguna configuracion de CORS con credenciales. API_PROXY_TARGET
4 // solo existe en el entorno de servidor, nunca como variable
  NEXT_PUBLIC_.
5 async rewrites() {
6   return [
7     { source: "/api/:path*", destination: `${API_PROXY_TARGET}/api/:path
      */` },
8     { source: "/health/", destination: `${API_PROXY_TARGET}/health/` },
9   ];
10 }

```

Extracto de código 6.3: Reescritura del mismo origen hacia el backend (apps/web/next.config.ts).




Figura 6.4: Vista de recomendaciones organizada por estanterías, con tema oscuro. Fuente: captura del proyecto.




Figura 6.5: Vista detallada de recomendaciones, con las señales de afinidad y tema oscuro. Fuente: captura del proyecto.

6.5. Pruebas y verificación

La verificación combina pruebas de backend contra PostgreSQL real (unitarias e integración en una única suite pytest, sin separarlas en conteos independientes), pruebas de frontend con Vitest y un recorrido de navegador con Playwright que integra los casos de accesibilidad mediante axe, sin un conteo aislado solo de

accesibilidad. El cierre de evidencia de la Fase 7, ejecutado el 14 de septiembre de 2026 y registrado en docs/verification/phase-07-launch-gate.md y en 07-VERIFICATION.md, deja como última regresión completa 736 pruebas de backend, 70 de frontend y 56 de navegador, las tres en verde y sin omitidas. Las evidencias de seguridad, migraciones, privacidad, importación y exportación se citan desde docs/verification/.

La estrategia combina cuatro niveles. Las pruebas unitarias y de integración del backend se ejecutan con pytest contra una instancia real de PostgreSQL 18.6, sin sustituirla por una base en memoria, porque el sistema depende de restricciones, transacciones y búsqueda de trigramas que solo se comportan igual sobre el motor real. Las pruebas del frontend usan vi test para la lógica y los componentes, con una prueba de paridad de claves de traducción. Las pruebas de extremo a extremo usan Playwright sobre un navegador real, con la biblioteca axe para las comprobaciones automáticas de accesibilidad frente a las Pautas de Accesibilidad para el Contenido Web (WCAG) 2.2 [19]. Por último, una prueba de humo se ejecuta contra la URL pública desplegada y rechaza un despliegue con la revisión equivocada, tráfico entre orígenes inesperado o peticiones fallidas.

Las comprobaciones de axe cubren el catálogo, el detalle, el registro, las recomendaciones, la página de inicio, el acceso y las fuentes, en escritorio a 1280 por 800 píxeles y en móvil a 375 por 812 píxeles.

6.5.1. Verificación de los datos y del laboratorio

La verificación de los datos y del laboratorio se dividió en dos grupos. El primero comprobó que los datos y sus contratos eran correctos: 70 pruebas del catálogo cubrieron la importación de campos de rating, los snapshots insert-only y la reconciliación determinista de RAWG; 54 pruebas de la aplicación evaluation cubrieron el cargador de protocolo, las particiones y las métricas. El segundo comprobó las primitivas de recomendación: 48 pruebas cubrieron el baseline aleatorio, el coseno, los vectores de contenido, el perfil de usuario, la caché WorkFeatureVector y el cálculo del perfil de rating por género.

Las propiedades relevantes se verificaron con casos pequeños y respuestas conocidas. El baseline aleatorio devuelve el mismo orden para la misma semilla, no devuelve obras de la biblioteca y no sale del corpus gobernado. La similitud coseno queda acotada entre cero y uno, es exactamente uno para vectores iguales no nulos y vale cero para vectores ortogonales o sin norma. Las métricas se comparan con cálculos manuales, mientras que el split rechaza particiones cuyo train, validation y test no sean disjuntos y completos.

La prueba de datos a escala también dejó una evidencia reproducible. El enriquecimiento RAWG se ejecutó en 18 lotes y una repetición de un lote ya procesado insertó cero snapshots adicionales. La huella de GameWork.rating permaneció idéntica antes y después, lo que demuestra que el enriquecimiento no muta el valor vivo del catálogo. Esta evidencia prueba integridad e idempotencia; no prueba que RAWG haya mejorado la calidad de las recomendaciones.

Las tablas de precisión, recall, nDCG y MAP de la comparación completa, con las 16 variantes evaluadas, sus contrastes de significación estadística y sus amenazas a la validez, se presentan en el Capítulo 7.

6.5.2. Gates de evidencia y verificación independiente

Además de las pruebas, el repositorio tiene gates deterministas que protegen la evidencia. El gate `check-secrets.ps1` escanea el árbol de Git, los paquetes de construcción, las capas de las imágenes y los registros capturados en busca de cadenas con forma de credencial, y se autoverifica primero contra señuelos sintéticos. El gate `check-evidence.ps1` valida el registro de agentes descrito en la Sección 3.3, y el gate `check-dependencies.ps1` comprueba la lista permitida de dependencias de la Sección 6.1. Los gates `verify-igdb-*.ps1` comprueban el contenido del registro de decisión de IGDB, la evidencia del sondeo y la ejecución de importación sobre una base de datos fresca.

Cada incremento del sistema se sometió a la verificación independiente de su objetivo que describe la Sección 3.3, que comprueba el código contra los criterios de éxito en lugar de leer los resúmenes de plan. El recorrido vertical inicial se verificó con cinco de cinco criterios de éxito, con dos elementos manuales de accesibilidad aceptados como limitaciones nombradas: el reflujo al cuatrocientos por ciento de zoom y una pasada con lector de pantalla. El catálogo a escala real, el rediseño de la interfaz y los recomendadores se verificaron con cuatro de cuatro criterios. La Tabla 6.4 resume esos criterios.

Criterio	Enunciado	Veredicto
SC1	Catálogo a escala real con fuente IGDB, con licencia, atribución y procedencia documentadas.	Verificado
SC2	Ordenar y filtrar el catálogo por plataforma, género y otros metadatos.	Verificado
SC3	La interfaz se lee como un producto de catalogación profesional.	Verificado
SC4	Página de recomendaciones por géneros según la actividad propia, distinta del baseline de popularidad.	Verificado

Tabla 6.4: Criterios de éxito verificados y su veredicto.

El criterio SC3, la calidad visual de producto, se cerró con la aprobación final. Empezó como aprobación anticipada condicional, mientras se estaba desconectado. Quedó confirmada sin condiciones tras una revisión remota de dieciocho capturas del entorno local que cubrían las cuatro superficies principales en escritorio y en móvil, ambos temas y una segunda cuenta con colección vacía como prueba visual de independencia.

6.5.3. Revisión de código

Ya con el sistema completo, el revisor de código de la Sección 3.3 examinó todo el árbol con una postura adversarial de búsqueda de defectos. La revisión encontró dieciséis hallazgos, cuya distribución por severidad recoge la Tabla 6.5. Se autorizó aplicar la totalidad de los hallazgos, que se corrigieron en cinco tandas confirmadas, cada una con las pruebas ejecutadas después.

Severidad	Hallazgos	Estado
Crítica	0	Ninguno
Alta	3	Corregidos
Media	6	Corregidos
Baja	7	Corregidos
Total	16	16 corregidos

Tabla 6.5: Hallazgos de la revisión de código de todo el repositorio.

Los tres hallazgos de severidad alta ilustran el valor de una revisión con contexto independiente. El primero era que la configuración de DRF dejaba habilitada de forma silenciosa la autenticación básica en todo punto de acceso autenticado, lo que abría una vía de adivinación de contraseñas sin límite de ritmo y una ruta de cambio de estado exenta de la protección contra falsificación de petición en sitios cruzados. El segundo era que una reimportación troceada del catálogo de IGDB tras una pasada completa podía saltarse en silencio un rango de identificadores ya recorrido y aun así declararse completa con una huella nueva. El tercero era que el arranque de producción usaba el servidor de desarrollo de Django, que su documentación desaconseja explícitamente. Los tres se corrigieron, el segundo con un campo de esquema nuevo y una migración, el tercero con la incorporación del servidor gunicorn.

La revisión también dejó constancia de las áreas sanas: ausencia de inyección de SQL, con todo el uso del ORM parametrizado; validación minuciosa de las consultas del catálogo; acotación de propiedad en todas las vistas de datos personales; escrituras transaccionales con bloqueo de fila y restricciones de unicidad como guarda real de carreras; higiene de secretos con redacción en registros y excepciones.

Tras la revisión de producto del proyecto, una tanda de correcciones se aplicó sobre la rama principal. La página de inicio dejó de mostrar una llamada a la acción de acceso redundante. El formulario de registro pasó a devolver los incumplimientos concretos de la política de contraseñas en lugar de un mensaje impreciso. La comparación del nombre de usuario en el acceso se hizo insensible a mayúsculas, para casar con la comprobación de unicidad, que ya lo era. Se añadió un punto de acceso pequeño, GET /api/accounts/me/, para que la barra de navegación pueda nombrar la cuenta activa.

Las cifras anteriores respaldan afirmaciones acotadas. El sistema tiene una cobertura de pruebas amplia sobre PostgreSQL real, una accesibilidad automática

sólida aunque no exhaustiva y una revisión de seguridad de todo el árbol con sus hallazgos corregidos. Esas cifras no respaldan ninguna medida de rendimiento bajo carga, de recuperación ante desastre ni de calidad de recomendación, que se mide aparte en el Capítulo 7. Los dos elementos manuales de accesibilidad del recorrido inicial siguen abiertos y declarados como tales.

6.6. Despliegue

La restricción de partida del despliegue público es la misma que ya fijó su diseño: coste cero, sin introducir ninguna tarjeta de pago ni habilitar ningún recurso de facturación. La Tabla 6.6 recoge el contrato de cada superficie.

Superficie	Servicio	Contrato
Interfaz de navegador	Vercel Hobby	Construye el frontend Next.js; reenvía del lado del servidor las rutas de la API y de salud hacia Render.
API	Render Free	Construye la imagen de la API con el catálogo local congelado y expone la ruta de salud.
Base de datos	Neon Free	Proyecto autumn-breeze-06234770, rama production; suministra PostgreSQL a Render.

Tabla 6.6: Topología pública aprobada, de coste cero.

El navegador solo ve el origen HTTPS de Vercel, que reenvía las rutas de la API como describe la Sección 5.3. En Render, la cadena de arranque encadena migración e importación del catálogo; solo entonces cede el control al servidor gunicorn, con cada paso idempotente y protegido con un bloqueo consultivo, de modo que un paso fallido detiene el arranque, tal como resume la Figura 6.6.




Figura 6.6: Topología de despliegue público y cadena de arranque en Render, en la que cada paso es idempotente y un paso fallido detiene el arranque. Docker Compose local (base de datos, API y frontend) construye las mismas imágenes sin depender de estos tres servicios.

Docker Compose sigue siendo el entorno reproducible canónico (Sección 6.1). La equivalencia con el despliegue público es funcional, de versiones, de commit y de datos, no de imagen byte a byte: el frontend público lo construye Vercel de forma nativa y no ejecuta la imagen de Docker del frontend, una diferencia de despliegue documentada, no una divergencia de comportamiento. Si cualquier servicio gratuito duerme, cambia sus términos o desaparece, el entorno local sigue disponible sin conexión. Los límites conocidos del nivel gratuito se declaran de forma explícita: el servicio de la API en Render duerme tras quince minutos sin tráfico, de modo que un visitante puede encontrar un arranque en frío de cerca de un minuto; las cuotas mensuales de los tres proveedores pueden suspender un servicio, y el nivel gratuito no promete copias de seguridad ni restauración.

La demostración pública está en vivo desde el 5 de septiembre de 2026, con la prueba de humo en verde contra la revisión desplegada. En ese despliegue sirve la interfaz anterior al rediseño contra el corpus curado de ciento cincuenta juegos de Wikidata: el rediseño de la interfaz y el catálogo a escala real no están en el despliegue público, sino integrados en la rama principal y ejecutados en el entorno local de Docker Compose. El frontend rediseñado llegó a construirse en Vercel, pero la base de datos desplegada todavía contiene solo el corpus curado, de modo que la vista de catálogo da error contra ese despliegue; se revisó esta situación y se decidió dejar el despliegue público actual como está por ahora, con la demostración ante el tribunal ejecutándose desde el entorno local reproducible. Conectar el despliegue a datos reales de internet (cargar el catálogo de IGDB en una base de datos desplegada, aplicar las migraciones nuevas y ajustar la

configuración de hosts y de proxies) queda pospuesto al final del proyecto: es una decisión registrada, no un defecto pendiente.

Este capítulo ha descrito la construcción, la verificación y el despliegue del sistema. El capítulo siguiente presenta la evaluación experimental de los algoritmos de recomendación que se ejecutan sobre él.

7. Evaluación y resultados

Con los dieciséis algoritmos ya formulados en la Sección 5.5, este capítulo los somete al protocolo de evaluación offline, con las métricas definidas en la Sección 2.2, y presenta los resultados publicados junto con una discusión honesta de lo que permiten y de lo que no permiten concluir. El énfasis no está en declarar un ganador, sino en dejar trazable cada cifra hasta el corpus, la semilla, el reparto y la configuración exactos que la produjeron.

La evaluación se ejecuta sobre la misma plataforma descrita en los capítulos anteriores: los usuarios sintéticos, sus bibliotecas y el corpus gobernado viven en la misma base de datos que sirve la aplicación.

7.1. Protocolo de evaluación

La evaluación publicada se ejecutó offline con el corpus congelado 2026.09.2. La población experimental contiene 400 usuarios sintéticos activos, generados de forma determinista; 79 cumplen la elegibilidad del split de prueba. Los perfiles se generan a partir de arquetipos (monogénero severo y generoso, omnívoro medio, completista de saga, explorador de novedades, coleccionista de pendientes, jugador ocasional con arranque en frío y veterano de biblioteca grande) que varían el número de géneros preferidos, el tamaño de la biblioteca, la generosidad al puntuar y la mezcla de estados, y llevan el marcador *synthetic-eval-user* para no contaminar el baseline de popularidad de la aplicación. No se utilizaron usuarios reales. El protocolo v15 fija semilla, versiones, snapshots, hashes, candidatas y exclusiones antes de consumir el test. La semilla permite reproducir esta ejecución, pero no sustituye un estudio de sensibilidad con múltiples semillas.

El protocolo vigente, v15, usa *leave-fraction-out* por usuario, no *leave-one-out*: retiene varios ítems relevantes por persona en lugar de uno solo. Una obra relevante es una entrada terminada o valorada con al menos siete medios puntos, con un piso adicional de calidad externa (valoración agregada de origen de al menos 70 puntos) sobre las candidatas a retener. Para cada usuario, el runner localiza su etiqueta de contenido con más peso en el perfil y retira de ella un $\lceil 0,3 \times \text{tamaño del grupo de esa etiqueta} \rceil$ de obras, nunca menos de una, retrocediendo de una en una si la retirada desplazara esa etiqueta del primer puesto del perfil restante. Cuando ese mecanismo no se puede construir para un usuario (sin ninguna señal de etiqueta de contenido, o sin candidatas que superen el piso de calidad), el runner recurre al *leave-one-out* simple de un único ítem en lugar de excluir a esa persona del estudio; solo queda fuera quien no tiene ningún positivo elegible en absoluto. Sobre los setenta y nueve usuarios evaluables, este mecanismo retuvo doscientos dos ítems en total, una media de 2,56 por usuario con un rango de uno a cinco. Todos los algoritmos reciben el mismo manifiesto de candidatas; el

diseño evita *leakage*: ningún ítem retenido participa en la construcción del perfil, mientras que su presencia entre las candidatas permite medir si se recupera.

Se calcula $K \in \{5, 10, 20\}$. Si R_u es el conjunto relevante retenido de un usuario y L_u^K los primeros K ítems de su lista, $Precision@K = |L_u^K \cap R_u|/K$ y $Recall@K = |L_u^K \cap R_u|/|R_u|$. Al retener varios ítems por usuario, $Recall@K$ deja de ser binario y se convierte en una fracción continua, lo que aporta más información por comparación que el *leave-one-out* de una sola versión anterior del protocolo. El nDCG y el MAP, definidos en la Sección 2.2, se calculan sobre la misma lista. El protocolo también conserva diversidad intra-lista, novedad, coberturas y concentración cuando el artefacto permite estimarlas.

7.2. Evolución del protocolo: tres intentos, no uno

El protocolo v15 descrito arriba no fue el primero que se congeló y se ejecutó hasta el final contra el split de prueba. Lo precedieron dos intentos completos, v12 y v14, cada uno ejecutado una sola vez sobre el mismo split de test, con sus propios resultados publicados y conservados sin alterar. Repasarlos aquí no es un ejercicio de transparencia añadido: la forma concreta del protocolo v15 (retención por fracción sobre una etiqueta propia de cada usuario, piso de calidad externa, población con mínimo garantizado) es la respuesta directa a dos problemas reales que esos dos intentos anteriores dejaron medidos, no una elección de diseño arbitraria.

El protocolo v12 (10 de septiembre de 2026) fue el primer cálculo congelado hasta el final. Su resultado no fue una comparación entre algoritmos, sino un hallazgo metodológico: el setenta y cuatro por ciento de los setenta y tres usuarios evaluables de aquel split (cincuenta y cuatro de setenta y tres) caía en un modo de «historial insuficiente» del recomendador de contenido en cuanto el *leave-one-out* retiraba su único positivo elegible, porque la población sintética de entonces no garantizaba un mínimo de positivos por biblioteca. En ese modo, las diez variantes de contenido y sus derivadas dejaban de usar similitud de etiquetas y colapsaban a la misma ordenación por valoración y popularidad que ya usaban los baselines, de modo que quince de los dieciséis algoritmos publicaron precisión, recall, nDCG y MAP exactamente en cero. La prueba de Friedman fue significativa ($\chi^2 = 30,00$, $p = 0,0119$, $n = 73$), pero ninguna de las ciento veinte comparaciones por pares sobrevivió la corrección de Holm: bajo ese protocolo, ningún algoritmo era declarable superior a otro. Se verificó que no era un fallo del código de puntuación (los vectores de contenido coincidían byte a byte con la caché versionada y el conjunto de candidatas era idéntico para los dieciséis algoritmos), sino una interacción entre dos piezas congeladas por separado: el generador de población sintética y el umbral de arranque en frío del recomendador de contenido.

Corregir esa interacción exigió dos cambios sucesivos. El primero, ya con población rediseñada, amplió el tamaño de biblioteca sintética, ensanchó la franja de popularidad de origen y garantizó un mínimo de cinco positivos elegibles por biblioteca, lo que eliminó por completo el modo de historial insuficiente en el split

de prueba: pasó de afectar al setenta y cuatro por ciento de los usuarios a un cero por ciento. El segundo cambio añadió, sobre esa población ya corregida, un piso de calidad externa (valoración agregada de origen de al menos setenta puntos) al ítem que el *leave-one-out* podía retirar, para que el positivo retenido no dependiera solo del gusto personal simulado sino también de una señal de calidad independiente, cerrando un sesgo de popularidad conocido en la literatura de evaluación de recomendadores [15].

El protocolo v14 (11 de septiembre de 2026), con esos dos cambios ya aplicados, sí produjo un ganador defendible: *hybrid-weighted-cf-v1* ($nDCG@10 = 0,1526$) y *content-cbf-weighted-v1* (0,1452) superaron con significación a los baselines y a *recency-v1*, con catorce de las ciento veinte comparaciones por pares significativas tras Holm, frente a cero en v12 ($\chi^2 = 105,28$, $p = 1,29 \times 10^{-15}$, $n = 79$). La diversidad intra-lista y la concentración de recomendaciones mejoraron en la misma medida: el índice de concentración de Herfindahl-Hirschman pasó de un rango de 0,55 a 0,71 en v12, propio de un catálogo minúsculo de recomendaciones repetidas, a un rango de 0,005 a 0,03, consecuencia directa de que el contenido ya no colapsaba al mismo *fallback* que los baselines. Aun así, v14 seguía reteniendo un único ítem por usuario mediante *leave-one-out*: cada comparación por usuario solo podía acertar o fallar una vez, lo que limitaba cuántas diferencias entre algoritmos podían alcanzar significación. El colaborativo puro, por ejemplo, no llegó a diferenciarse de forma significativa de ningún otro algoritmo en v14, pese a tener un $nDCG@10$ más bajo que las variantes de contenido con mejor combinación.

Ese límite de potencia estadística, no un defecto de v14, es lo que motivó el cambio final a *leave-fraction-out* por etiqueta dominante propia de cada usuario que define el protocolo v15: retener varios positivos por persona en lugar de uno solo da a cada comparación más información por usuario sin necesidad de una población mayor. El resultado, ya presentado en la Sección 7.4, fue el esperado: de catorce comparaciones significativas en v14 a cincuenta y cuatro en v15, con una diferenciación entre contenido y colaborativo puro que v12 y v14 no tenían potencia estadística suficiente para establecer. Los tres protocolos y sus artefactos quedan versionados sin modificar: v15 no invalida ni reescribe los resultados de v12 o v14, los sustituye como publicación vigente por haber corregido, de forma medida y documentada, los problemas que los dos intentos anteriores dejaron al descubierto.

Conviene defender por qué v15 se acerca más a una prueba realista de lo que los algoritmos hacen, no simplemente a un protocolo ajustado para producir números más altos. La justificación no es que v15 favorezca a ningún algoritmo concreto, sino que corrige tres formas en las que v12 y v14 se apartaban de cómo se evalúa la recuperación en la literatura y de cómo el propio sistema puntúa.

La primera es de encuadre metodológico. Retirar y comprobar la recuperación de un subconjunto de valoraciones del historial de un usuario, en lugar de un único ítem, no es una invención de este proyecto: es la generalización natural del esquema *All-but-N*, ya nombrado así en la literatura desde Breese, Heckerman y Kadie [34] y sistematizado por Herlocker et al. [13], donde el *leave-one-out* que

usaban los protocolos v6 a v14 es simplemente el caso particular $N = 1$. v15 no sale de ese marco: solo deja de fijar N de forma global y lo calcula por usuario, en proporción al tamaño de su propio grupo de obras con esa etiqueta.

La segunda es de fidelidad a la señal que el sistema realmente usa. `facet_similarity()`, el código de puntuación que usan los dieciséis algoritmos tanto en la aplicación como en el laboratorio, combina cada familia de faceta como una suma ponderada, nunca como una decisión de un único rasgo ganador. Que la etiqueta retirada deje de ser la primera del perfil recalculado del usuario, en el 21,3 % de los casos verificados antes de congelar el protocolo, no convierte la prueba en menos válida: un perfil de contenido sigue apoyándose en esa etiqueta, con menos peso relativo, exactamente igual que se apoyaría en cualquier otra bajo el mismo mecanismo de puntuación [25]. Exigir que la etiqueta se mantuviera siempre en primer lugar habría sido, de hecho, la elección menos fiel al propio sistema, porque habría excluido usuarios reales para el algoritmo aunque no lo fueran para la prueba.

La tercera es de inclusión. Un usuario para el que el mecanismo por fracción no se puede construir cae al *leave-one-out* simple de los protocolos anteriores en lugar de quedar fuera, lo que evita el sesgo de selección contrario, el de quedarse solo con los usuarios más fáciles de evaluar y llamar a eso representativo.

Ninguno de los tres argumentos convierte v15 en evidencia sobre jugadores reales: sigue siendo una evaluación sobre una población sintética y un corpus concretos, como recuerda la Sección 7.5. Lo que sí establecen es que, dentro de esa simulación, v15 mide la pregunta que se propone medir (¿recupera el sistema contenido afín al gusto que la propia biblioteca del usuario ya demuestra?) con más fidelidad al mecanismo de puntuación real y con menos artefactos de diseño heredados que v12 o v14, no solo con mejores cifras.

7.3. Resultados publicados

La Tabla 7.1 resume $nDCG@10$, $MAP@10$ y tiempo de pared de la cohorte `active_history_10_to_20` incluidos en el artefacto v15. Se muestra una tabla compacta para evitar repetir cuatro métricas por tres valores de K ; el artefacto versionado `evaluation-400-test-2026-09-12-v15.artifact.json` y su transcripción en `docs/verification/evaluation-cohorts-400-test-2026-09-12-v15.md` preservan la transcripción completa para $K = 5, 10, 20$.

Tabla 7.1: Resultados v15 publicados para la cohorte indicada. No son resultados con usuarios reales.

Algoritmo	Familia	nDCG@10	MAP@10
random-v1	baseline	0.00000	0.00000
popularity-v1	baseline	0.00340	0.00098
content-cbf-weighted-v1	contenido	0.17245	0.10878
content-cbf-multiplicative-v1	contenido	0.08558	0.05934
content-cbf-twostage-v1	contenido	0.11724	0.06767
content-cbf-neg-v1	contenido	0.11778	0.07368
content-cbf-weighted-pop-v1	contenido + popularidad	0.15181	0.09826
content-cbf-multiplicative-pop-v1	contenido + popularidad	0.08517	0.05898
content-cbf-twostage-pop-v1	contenido + popularidad	0.11410	0.06551
content-cbf-neg-pop-v1	contenido + popularidad	0.09936	0.06134
recency-v1	contenido + novedad	0.00594	0.00422
content-cbf-mmr-v1	contenido + diversidad	0.13888	0.08685
content-cbf-mmr-pop-v1	contenido + diversidad	0.13824	0.09353
cf-user-knn-v1	colaborativo	0.02098	0.01099
hybrid-weighted-cf-v1	híbrido	0.16989	0.10758
hybrid-mmr-v1	híbrido + diversidad	0.15913	0.09741

La Tabla 7.2 conserva $nDCG$ en los tres cortes solicitados para el catálogo completo de variantes v15. Precision, recall y MAP permanecen en el artefacto y en la matriz de algoritmos para evitar una tabla de dieciséis filas y doce métricas que perdería legibilidad.

Tabla 7.2: $nDCG$ publicado por algoritmo y corte K en v15.

Algoritmo	Familia	$K = 5$	$K = 10$	$K = 20$
random-v1	baseline	0.00000	0.00000	0.00000
popularity-v1	baseline	0.00191	0.00340	0.00340
content-cbf-weighted-v1	contenido	0.14114	0.17245	0.18987
content-cbf-multiplicative-v1	contenido	0.07707	0.08558	0.10241
content-cbf-twostage-v1	contenido	0.08827	0.11724	0.14002
content-cbf-neg-v1	contenido	0.09656	0.11778	0.12992
content-cbf-weighted-pop-v1	contenido + popularidad	0.13179	0.15181	0.17409
content-cbf-multiplicative-pop-v1	contenido + popularidad	0.07677	0.08517	0.10200
content-cbf-twostage-pop-v1	contenido + popularidad	0.08338	0.11410	0.14538
content-cbf-neg-pop-v1	contenido + popularidad	0.08602	0.09936	0.11582
recency-v1	contenido + novedad	0.00594	0.00594	0.00594
content-cbf-mmr-v1	contenido + diversidad	0.11600	0.13888	0.16160
content-cbf-mmr-pop-v1	contenido + diversidad	0.12211	0.13824	0.15362
cf-user-knn-v1	colaborativo	0.01585	0.02098	0.03163
hybrid-weighted-cf-v1	híbrido	0.14305	0.16989	0.18962
hybrid-mmr-v1	híbrido + diversidad	0.13195	0.15913	0.17401

La diferencia numérica más visible en $nDCG@10$ aparece entre content-cbf-weighted-v1 y los baselines. El híbrido ponderado queda próximo a esa variante de contenido, mientras que el colaborativo aislado recupera menos positivos bajo este split. Esta observación es interna al artefacto: no prueba que contenido sea superior en una comunidad real, ni que los pesos del híbrido sean óptimos. De las tres variantes que publica la aplicación (Sección 5.5.4), content-cbf-weighted-v1 obtiene el mejor $nDCG@10$ (0.17245), content-cbf-mmr-pop-v1 queda algo por debajo (0.13824) y recency-v1 apenas llega a 0.00594, lo que es coherente con su papel de variante de descubrimiento, que prioriza la novedad sobre la afinidad. Para $K = 5$, hybrid-weighted-cf-v1 publica $nDCG = 0,14305$, frente a 0,14114 de Weighted. Para $K = 20$, Weighted publica 0,18987 y el híbrido ponderado 0,18962. La proximidad de esas cifras ilustra por qué no basta con mirar la diferencia numérica sin contrastarla; la Sección 7.4 retoma esta misma comparación con una prueba estadística. El baseline aleatorio permanece en cero en la cohorte publicada; popularidad alcanza 0,00340 en $nDCG@10$, lo que contextualiza la señal de contenido pero no mide utilidad subjetiva. La Figura 7.1 ordena los dieciséis algoritmos por $nDCG@10$ y señala las tres variantes que publica la aplicación.

$nDCG$ y MAP resumen la recuperación en una única cifra por algoritmo, pero no responden directamente a la pregunta más intuitiva: ¿a cuántas personas le




Figura 7.1: $nDCG@10$ de los dieciséis algoritmos en la evaluación v15, por familia. El borde grueso marca las tres variantes publicadas en la aplicación.

funcionó? La Tabla 7.3 lo hace explícito para $K = 10$, sobre los doscientos dos ítems retenidos y los setenta y nueve usuarios evaluables.

Tabla 7.3: Éxitos por algoritmo a $K = 10$: ítems retenidos recuperados sobre 202; usuarios que recuperaron al menos uno de los suyos sobre 79.

Algoritmo	Ítems@10 (/202)	Usuarios $\geq 1@10$ (/79)
content-cbf-weighted-v1	48	39 (49 %)
hybrid-weighted-cf-v1	48	38 (48 %)
hybrid-mmr-v1	42	35 (44 %)
content-cbf-weighted-pop-v1	38	34 (43 %)
content-cbf-mmr-v1	36	32 (41 %)
content-cbf-neg-v1	34	28 (35 %)
cf-user-knn-v1	7	7 (9 %)
popularity-v1	2	2 (3 %)
recency-v1	1	1 (1 %)
random-v1	0	0 (0 %)

Leída así, la mejor variante de contenido devuelve al menos uno de los juegos retenidos del usuario, dentro de las diez primeras posiciones, casi a la mitad de las personas evaluables (49 %), frente al 9 % del colaborativo puro y el 3 % o menos de los baselines; a $K = 20$ esa cifra sube al 58 % para content-cbf-weighted-v1 (cuarenta y seis de setenta y nueve usuarios). Esta tasa de éxito por usuario y el $nDCG@10$ de la Tabla 7.1 miden cosas distintas y no deben confundirse: la primera cuenta aciertos binarios por persona, mientras que la segunda además descuenta la posición exacta del acierto dentro de la lista, por lo que una tasa de éxito alta no implica un $nDCG$ igual de alto si los aciertos tienden a aparecer hacia el final del top- K en vez de al principio.

7.4. Significación estadística

Las diferencias de la Tabla 7.1 se sometieron a contraste antes de interpretarlas, con una cadena de pruebas pensada para el caso en que dieciséis algoritmos se miden sobre exactamente los mismos setenta y nueve usuarios (medidas repetidas, no muestras independientes) y se quiere comparar cada par sin inflar el número de falsos positivos que salen solo por probar muchas comparaciones a la vez. La cadena tiene cuatro piezas, todas ellas procedimientos estadísticos estándar aplicados a este problema concreto, no invenciones del proyecto.

Primero, una prueba de **Friedman** sirve de ómnibus: comprueba, con un único contraste, si existe alguna diferencia entre los dieciséis algoritmos antes de gastar el presupuesto de comparaciones en mirar pares sueltos. Es no paramétrica (no asume que los valores de $nDCG$ se distribuyan de forma normal, algo que no se puede dar por hecho con solo setenta y nueve observaciones) y adecuada para medidas repetidas: cada usuario aporta un ranking entre los dieciséis algoritmos; la prueba contrasta si esos rankings son consistentes entre sí. Sobre $nDCG@10$, rechaza la hipótesis de igualdad con $\chi^2 = 258,07$ y $p = 2,69 \times 10^{-46}$.

Segundo, confirmada la existencia de alguna diferencia, cada uno de los ciento veinte pares posibles de algoritmos se contrasta con una prueba de **Wilcoxon de rangos con signo pareada**: para cada usuario se calcula la diferencia de $nDCG@10$ entre los dos algoritmos del par; la prueba comprueba si esas diferencias pareadas se alejan de cero de forma consistente, sin asumir tampoco su distribución. Es la elección natural aquí porque los dos algoritmos de cada par se miden sobre las mismas setenta y nueve personas, no sobre grupos distintos.

Tercero, probar ciento veinte pares a la vez con un umbral $p < 0,05$ fijo produciría, solo por azar, varios falsos positivos aunque ningún algoritmo fuera realmente distinto de otro (el problema de comparaciones múltiples). La **corrección de Holm** ajusta el umbral de significación de cada una de las ciento veinte comparaciones, ordenadas de menor a mayor p sin corregir, de forma escalonada y más potente que una corrección de Bonferroni simple sin dejar de controlar el error de tipo I acumulado. Cincuenta y cuatro de las ciento veinte comparaciones siguen siendo significativas después de este ajuste.

Cuarto, además del contraste de hipótesis, el artefacto conserva un **intervalo de confianza por bootstrap BCa** (*bias-corrected and accelerated*, dos mil remuestreos, confianza del 95 %, semilla fija) para el $nDCG@10$ de cada algoritmo, que da un rango de valores plausibles en lugar de una única cifra puntual y no exige asumir ninguna forma concreta para la distribución del estadístico. La Tabla 7.4 recoge las comparaciones por pares más relevantes para la narrativa de este capítulo; la lista completa de las ciento veinte vive en el artefacto versionado.

Tabla 7.4: Comparaciones por pares más relevantes sobre $nDCG@10$, con corrección de Holm sobre las ciento veinte comparaciones totales.

Comparación	$\Delta nDCG@10$	p ajustado
content-cbf-weighted-v1 vs. random-v1	+0,1725	0,00001
content-cbf-weighted-v1 vs. popularity-v1	+0,1691	0,00001
hybrid-weighted-cf-v1 vs. random-v1	+0,1699	0,00001
cf-user-knn-v1 vs. content-cbf-weighted-v1	-0,1515	0,00004
cf-user-knn-v1 vs. hybrid-weighted-cf-v1	-0,1489	0,00004

Dos lecturas se derivan de este contraste. La primera es que tanto las variantes de contenido como los híbridos superan a los dos baselines y a recency-v1 con significación sobrada, lo que sí permite descartar el azar como explicación de esas diferencias concretas, bajo este corpus y esta población. La segunda, nueva en este protocolo frente a versiones anteriores, es que el colaborativo puro (cf-user-knn-v1) resulta significativamente peor que ocho de las diez variantes de contenido, una diferenciación que la potencia estadística de protocolos previos no alcanzaba a establecer con esta claridad. Esa lectura tiene un matiz importante: esta prueba mide específicamente la recuperación de obras de la etiqueta de contenido dominante del perfil de cada usuario, y cf-user-knn-v1 no usa etiquetas en absoluto, sino similitud de patrones de valoración entre usuarios. La diferencia es real y significativa, pero mide precisamente el terreno que la señal colaborativa no modela; no es evidencia de que el filtrado colaborativo sea inferior en una tarea distinta, como recuperar valoraciones de usuarios con gustos parecidos sin restricción de género. Los híbridos combinan ambas señales en parte por esta razón: para no depender de ninguna de las dos en solitario.

7.5. Diversidad, cobertura y amenazas a la validez

MMR introduce un objetivo distinto de la recuperación puntual: reducir redundancia entre elementos ya seleccionados. Sus resultados deben leerse junto con diversidad intra-lista, novedad, cobertura del catálogo, cobertura de predicción y HHI cuando el artefacto los publica. Una mejora de diversidad no compensa automáticamente una pérdida de $nDCG$, ni la métrica de acierto debe ocultar concentración. SavePoint mantiene estas medidas separadas para que el compromiso sea auditable.

Las amenazas principales son población sintética, un solo consumo del test y dependencia de metadatos externos gobernados. El corpus y el snapshot son fortalezas de reproducibilidad, pero acotan la generalización: la significación estadística de la Sección 7.4 respalda que las diferencias observadas no son ruido bajo este corpus y esta población, no que se sostengan sobre usuarios reales. Un estudio posterior debería incluir más semillas, sensibilidades de hiperparámetros, datos observados con consentimiento y evaluación con participantes, sin mutar el artefacto v15 ya publicado.

Este capítulo ha presentado la evaluación experimental de los algoritmos. El capítulo siguiente cierra la memoria con el grado de cumplimiento de los objetivos y las líneas de continuación.

8. Conclusiones y continuidad

Este capítulo cierra la memoria. Valora el grado de cumplimiento de los objetivos fijados en el Capítulo 1, resume las aportaciones del trabajo, declara sus limitaciones sin suavizarlas y esboza las líneas de continuidad que el sistema deja abiertas.

8.1. Grado de cumplimiento de los objetivos

El objetivo general, construir una plataforma de catalogación que funcionara también como banco de pruebas reproducible de recomendación, se cumple en su totalidad. El catálogo tiene identidad canónica propia, procedencia por obra y licencia documentada, a escala real sobre el catálogo importado de IGDB. Una persona usuaria puede mantener su lista de pendientes, valorar juegos e inventariar copias físicas y digitales con su formato y su edición, con privacidad de perfil y relaciones sociales gobernadas por completo en el backend. El protocolo de evaluación offline quedó congelado, versionado y probado antes de ejecutar ninguna comparación. Esa comparación se llevó a cabo: las tres familias de recomendación (basada en contenido, colaborativa e híbrida), descritas con su formulación completa en el Sección 5.5, se compararon bajo ese protocolo en el Capítulo 7 frente a los baselines de referencia. De los objetivos específicos solo quedan pendientes, de forma parcial, dos piezas del contrato de evaluación, que recoge la Sección 8.2. Cada incremento del sistema se cerró con sus criterios de éxito verificados de forma independiente, según la disciplina descrita en el Capítulo 3.

8.2. Limitaciones y trabajo futuro

Las limitaciones conocidas se declaran sin ocultarlas. La evidencia experimental publicada procede de una única ejecución del test sobre usuarios sintéticos, setenta y nueve de ellos evaluables, con una sola semilla: es suficiente para comparar algoritmos entre sí bajo un protocolo común, con significación estadística ya calculada sobre esa muestra (bootstrap BCa, Friedman, Wilcoxon y corrección de Holm), pero no permite afirmar que esa significación sea estable frente a otra semilla o a otra población sintética sin repetir el experimento. La cobertura de valoraciones externas del catálogo es parcial, como corresponde a una fuente agregada de terceros y no a un panel de crítica propio; esa parcialidad se propaga, de forma documentada, a cualquier señal de calidad externa que la use. La captura de entorno de ejecución y consumo de recursos, ya disponible en el ejecutor paralelo para comparaciones futuras, no se retroproyectó sobre la ejecución v15 ya cerrada, de modo que esa ejecución concreta carece de ese detalle.

El despliegue público, descrito en la Sección 6.6, sirve todavía el catálogo curado inicial y no el catálogo a escala real: esa conexión se pospuso de forma deliberada al final del proyecto; la demostración ante el tribunal se ejecuta desde el entorno local reproducible.

El banco de pruebas que esta memoria deja construido y ya explotado habilita líneas de continuación concretas, no genéricas. La primera es repetir el protocolo publicado con nuevas semillas y con cohortes sintéticas adicionales, para separar lo que es una diferencia consistente entre algoritmos de lo que podría ser ruido de una única muestra, y aplicar sobre la nueva ejecución la captura de entorno y consumo de recursos que el ejecutor paralelo ya sabe registrar. La segunda es estudiar la sensibilidad del sistema a sus propios hiperparámetros locales (los pesos de familia de facetas, la mezcla híbrida, el factor de diversidad), en lugar de tratarlos como constantes fijadas de una vez. La tercera, ya fuera del núcleo de recomendación, es conectar el despliegue público al catálogo a escala real. Cualquier extensión de este trabajo deberá crear su propio protocolo y su propio artefacto versionado, sin alterar de forma retroactiva la evidencia ya publicada.

8.3. Aportaciones y valoración final

Las tres aportaciones anunciadas en la Sección 1.1 quedan entregadas. El producto está construido, verificado y documentado. El banco de pruebas está explotado: un corpus citable, una población sintética documentada y un protocolo offline congelado sostienen una comparación real entre dieciséis algoritmos, con sus artefactos, semillas y configuraciones conservados para que un tercero pueda reproducir cada cifra publicada. Y la metodología de ingeniería que gobernó el proyecto, versionada en el repositorio con su árbol de planificación, sus registros de decisión y su registro de agentes, permite reconstruir el rastro completo de decisiones. Así, el trabajo entrega las dos mitades de la idea de la que parte SavePoint: un producto de catalogación y un banco de pruebas de recomendadores cuyos resultados se pueden volver a obtener a partir de los mismos artefactos versionados.

Bibliografía

- [1] Goodreads. About goodreads. Página oficial, 2026. URL <https://www.goodreads.com/about/us>. Consultado en 2026.
- [2] Letterboxd. Welcome to letterboxd. Documentación oficial, 2026. URL <https://letterboxd.com/welcome/>. Consultado en 2026.
- [3] Backloggd. Backloggd: A video game collection tracker. Página oficial, 2026. URL <https://backloggd.com/about/>. Consultado en 2026.
- [4] Wikimedia Foundation. Wikidata: Licensing. Wiki de la comunidad Wikidata, 2025. URL <https://www.wikidata.org/wiki/Wikidata:Licensing>.
- [5] Wikimedia Foundation. Commons: Reusing content outside wikimedia. Wiki de Wikimedia Commons, 2025. URL https://commons.wikimedia.org/wiki/Commons:Reusing_content_outside_Wikimedia/en.
- [6] IGDB and Twitch Interactive. IGDB API documentation, version 4. Documentación oficial de la API, 2025. URL <https://api-docs.igdb.com/>.
- [7] Twitch Interactive, Inc. Twitch developer services agreement. Términos legales para desarrolladores, 2025. URL <https://legal.twitch.com/legal/developer-agreement/>.
- [8] RAWG. RAWG video games database API. Documentación oficial de la API, 2025. URL <https://rawg.io/apidocs>.
- [9] Francesco Ricci, Lior Rokach, and Bracha Shapira, editors. *Recommender Systems Handbook*. Springer, 3 edition, 2022. doi: 10.1007/978-1-0716-2197-4.
- [10] Charu C. Aggarwal. *Recommender Systems: The Textbook*. Springer, 2016. doi: 10.1007/978-3-319-29659-3.
- [11] Gediminas Adomavicius and Alexander Tuzhilin. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734–749, 2005. doi: 10.1109/TKDE.2005.99.
- [12] Robin Burke. Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, 12(4):331–370, 2002. doi: 10.1023/A:1021240730564.
- [13] Jonathan L. Herlocker, Joseph A. Konstan, Loren G. Terveen, and John T. Riedl. Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, 22(1):5–53, 2004. doi: 10.1145/963770.963772.

- [14] Asela Gunawardana and Guy Shani. Evaluating recommender systems. In *Recommender Systems Handbook*, pages 265–308. Springer, 2 edition, 2015. doi: 10.1007/978-1-4899-7637-6_8.
- [15] Paolo Cremonesi, Yehuda Koren, and Roberto Turrin. Performance of recommender algorithms on top-n recommendation tasks. In *Proceedings of the Fourth ACM Conference on Recommender Systems (RecSys)*, pages 39–46, 2010. doi: 10.1145/1864708.1864721.
- [16] Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002. doi: 10.1145/582415.582418.
- [17] Anthropic. Effective context engineering for AI agents. Documentación técnica de Anthropic, 2025. URL <https://www.anthropic.com/engineering>.
- [18] GSD Build. GSD: Método de desarrollo dirigido por especificación para agentes de código. Repositorio y documentación del proyecto, 2026. URL <https://github.com/gsd-build/get-shit-done>. Nombre empleado en SavePoint; documentación consultada en 2026.
- [19] World Wide Web Consortium. Web content accessibility guidelines (WCAG) 2.2. Recomendación del W3C, 2023. URL <https://www.w3.org/TR/WCAG22/>.
- [20] Django Software Foundation. Django documentation, version 5.2 LTS. Documentación oficial, 2025. URL <https://docs.djangoproject.com/en/5.2/>.
- [21] Tom Christie and Encode OSS. Django REST framework. Documentación oficial, 2025. URL <https://www.django-rest-framework.org/>.
- [22] The PostgreSQL Global Development Group. PostgreSQL 18 documentation. Documentación oficial, 2025. URL <https://www.postgresql.org/docs/18/>.
- [23] Vercel. Next.js documentation, App Router. Documentación oficial, 2025. URL <https://nextjs.org/docs/app>.
- [24] Meta Open Source. React documentation. Documentación oficial, 2025. URL <https://react.dev/>.
- [25] Michael J. Pazzani and Daniel Billsus. Content-based recommendation systems. In *The Adaptive Web: Methods and Strategies of Web Personalization*, volume 4321 of *Lecture Notes in Computer Science*, pages 325–341. Springer, 2007. doi: 10.1007/978-3-540-72079-9_10.
- [26] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing and Management*, 24(5):513–523, 1988. doi: 10.1016/0306-4573(88)90021-0.
- [27] Cornelis Joost van Rijsbergen. *Information Retrieval*. Butterworths, 2 edition, 1979.

- [28] Bradley Efron. *Large-Scale Inference: Empirical Bayes Methods for Estimation, Testing, and Prediction*. Cambridge University Press, 2010. doi: 10.1017/CBO9780511761362.
- [29] Paul Resnick, Neophytos Iacovou, Mitesh Suchak, Peter Bergstrom, and John Riedl. GroupLens: An open architecture for collaborative filtering of netnews. In *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work (CSCW)*, pages 175–186, 1994. doi: 10.1145/192844.192905.
- [30] Jaime Carbonell and Jade Goldstein. The use of MMR, diversity-based reranking for reordering documents and producing summaries. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 335–336, 1998. doi: 10.1145/290941.291025.
- [31] Sean M. McNee, John Riedl, and Joseph A. Konstan. Being accurate is not enough: How accuracy metrics have hurt recommender systems. In *CHI '06 Extended Abstracts on Human Factors in Computing Systems*, pages 1097–1101, 2006. doi: 10.1145/1125451.1125659.
- [32] Saúl Vargas and Pablo Castells. Rank and relevance in novelty and diversity metrics for recommender systems. In *Proceedings of the Fifth ACM Conference on Recommender Systems (RecSys)*, pages 109–116, 2011. doi: 10.1145/2043932.2043955.
- [33] Yehuda Koren, Robert Bell, and Chris Volinsky. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30–37, 2009. doi: 10.1109/MC.2009.263.
- [34] John S. Breese, David Heckerman, and Carl Kadie. Empirical analysis of predictive algorithms for collaborative filtering. In *Proceedings of the Fourteenth Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 43–52, 1998.